

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI



BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

NĂM HỌC 2024 – 2025

NGHIÊN CỨU THUẬT TOÁN NLP VÀ ỨNG DỤNG VÀO BÀI TOÁN PHÂN TÍCH THÁI ĐỘ TÍCH CỰC, TIÊU CỰC CỦA SINH VIÊN UTC2 TRÊN MẠNG XÃ HỘI FACEBOOK

Sinh viên thực hiện:

1. Phạm Thị Ngọc Oanh	CQ.63.CNTT	Bộ môn Công nghệ thông tin
2. Lê Minh Hoàng	CQ.63.CNTT	Bộ môn Công nghệ thông tin
3. Trần Phương Anh	CQ.63.CNTT	Bộ môn Công nghệ thông tin
4. Lê Đình Khôi	CQ.63.CNTT	Bộ môn Công nghệ thông tin
5. Đỗ Văn Thành Được	CQ.63.CNTT	Bộ môn Công nghệ thông tin

Người hướng dẫn: ThS. Trần Thị Dung

TP. Hồ Chí Minh, tháng 5 năm 2025

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI



BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

NĂM HỌC 2024 – 2025

**NGHIÊN CỨU THUẬT TOÁN NLP VÀ ỨNG DỤNG VÀO BÀI
TOÁN PHÂN TÍCH THÁI ĐỘ TÍCH CỰC, TIÊU CỰC CỦA SINH
VIÊN UTC2 TRÊN MẠNG XÃ HỘI FACEBOOK**

Sinh viên thực hiện:

1. Phạm Thị Ngọc Oanh	Nam, Nữ: Nữ	Dân tộc: Kinh
Lớp: CQ.63.CNTT	Ngành học: Công nghệ thông tin	Năm thứ: 3/4
2. Lê Minh Hoàng	Nam, Nữ: Nam	Dân tộc: Kinh
Lớp: CQ.63.CNTT	Ngành học: Công nghệ thông tin	Năm thứ: 3/4
3. Trần Phương Anh	Nam, Nữ: Nữ	Dân tộc: Kinh
Lớp: CQ.63.CNTT	Ngành học: Công nghệ thông tin	Năm thứ: 3/4
4. Lê Đình Khôi	Nam, Nữ: Nam	Dân tộc: Kinh
Lớp: CQ.63.CNTT	Ngành học: Công nghệ thông tin	Năm thứ: 3/4
5. Đỗ Văn Thành Được	Nam, Nữ: Nam	Dân tộc: Kinh
Lớp: CQ.63.CNTT	Ngành học: Công nghệ thông tin	Năm thứ 3/4

Người hướng dẫn: ThS. Trần Thị Dung

MỤC LỤC

MỤC LỤC	i
DANH MỤC HÌNH ẢNH	iii
DANH MỤC BẢNG BIỂU	iv
DANH MỤC VIẾT TẮT	v
LỜI MỞ ĐẦU	1
CHƯƠNG 1: TỔNG QUAN.....	2
1.1. Tình hình nghiên cứu.....	2
1.2. Lý do chọn đề tài	4
1.3. Mục tiêu, nội dung, phương pháp nghiên cứu của đề tài.....	6
1.3.1. Mục tiêu nghiên cứu.....	6
1.3.2. Nội dung nghiên cứu	7
1.3.3. Phương pháp nghiên cứu.....	8
1.4. Đối tượng và phạm vi nghiên cứu	9
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	10
2.1. Tổng quan về bài toán phân tích cảm xúc	10
2.1.1. Khái niệm và phạm vi ứng dụng	10
2.1.2. Các cấp độ phân tích cảm xúc	10
2.1.3. Các thách thức trong phân tích cảm xúc trong tiếng Việt	11
2.2 Tổng quan về xử lý ngôn ngữ tự nhiên	11
2.2.1. Khái niệm.....	12
2.2.2. Đặc thù của tiếng Việt trong NLP.....	12
2.2.3. Tiền xử lý văn bản tiếng Việt.....	13
2.3. Học máy trong phân tích cảm xúc.....	14
2.3.1. Biểu diễn văn bản	14
2.3.2. Các thuật toán học máy truyền thống.....	15
2.3.3. Ưu nhược điểm của phương pháp học máy truyền thống	16
2.4. Học sâu trong phân tích cảm xúc	17
2.4.1. Mạng nơ-ron tích chập cho xử lý văn bản.....	17
2.4.2. Mạng nơ-ron hồi quy	17
2.4.3. Mạng bộ nhớ dài-ngắn hạn.....	17
2.4.4. Cơ chế Attention và Self-Attention	17

2.4.5. Mô hình Transformer.....	18
2.4.6. BERT và các phiên bản của BERT cho tiếng Việt	18
CHƯƠNG 3: PHƯƠNG PHÁP PHÂN TÍCH CẢM XÚC ĐỀ XUẤT	20
3.1. Tổng quan về phương pháp phân tích cảm xúc đề xuất	20
3.2. Chi tiết các khối trong hệ thống	22
3.2.1. Thu thập dữ liệu.....	22
3.2.2. Quy trình và tiêu chí gán nhãn cảm xúc	23
3.2.3 Tiền xử lý dữ liệu.....	28
3.2.4. Các mô hình phân tích cảm xúc đề xuất.....	31
3.2.5. Huấn luyện và đánh giá mô hình.....	33
3.2.6 Triển khai và ứng dụng.....	34
3.3. Ứng dụng PhoBERT vào phân chia chủ đề	35
3.3.1. Kiến trúc mô hình	35
3.3.2 Ưu điểm của phương pháp	35
3.4. Ứng dụng PhoBERT trong việc trích xuất các từ tiêu cực và tích cực.....	36
CHƯƠNG 4:PHÁT TRIỂN HỆ THỐNG PHÂN TÍCH THÁI ĐỘ SINH VIÊN..	38
4.1. Cơ sở dữ liệu.....	38
4.1.1. Nguồn dữ liệu và quy trình thu thập.....	38
4.1.2. Thống kê dữ liệu.....	38
4.1.3. Tiền xử lý và phân chia dữ liệu	39
4.2. Độ đo đánh giá.....	39
4.3. Kết quả thực nghiệm.....	40
4.3.1. Cấu hình huấn luyện.....	40
4.3.2. Kết quả.....	42
4.4. Giao diện hệ thống.....	51
KẾT LUẬN VÀ KIẾN NGHỊ.....	55
TÀI LIỆU THAM KHẢO.....	58

DANH MỤC HÌNH ẢNH

Hình 2.1 Sơ đồ luồng quy trình xử lý ngôn ngữ tự nhiên	12
Hình 2.2. Quy trình tiền xử lý dữ liệu văn bản trong xử lý ngôn ngữ tự nhiên	14
Hình 3.1 Kiến trúc tổng thể của hệ thống phân tích cảm xúc	21
Hình 3.2 Quy trình gán nhãn dữ liệu cảm xúc	24
Hình 3.3 Luồng xử lý hệ thống phân tích cảm xúc từ fanpage theo yêu cầu	35
Hình 4.1 Phân bố dữ liệu theo các loại phản hồi.....	39
Hình 4.2 Biểu đồ so sánh hiệu suất các mô hình các chỉ số	43
Hình 4.3 So sánh training loss giữa các mô hình	44
Hình 4.4 So sánh validation loss giữa các mô hình.....	44
Hình 4.5 Diễn biến quá trình học của mô hình ViBERT4News.....	45
Hình 4.6 Diễn biến quá trình học của mô hình PhoBERT	45
Hình 4.7 Diễn biến quá trình học của mô hình XLM-RoBERTa	46
Hình 4.8 Diễn biến quá trình học của mô hình ViBERT	46
Hình 4.9 Diễn biến quá trình học của mô hình SVM.....	47
Hình 4.10 Diễn biến quá trình học của mô hình LSTM.....	47
Hình 4.11 Ma trận nhầm lẫn của mô hình ViBERT4news	48
Hình 4.12 Ma trận nhầm lẫn của mô hình PhoBERT	48
Hình 4.13 Ma trận nhầm lẫn của mô hình SVM	49
Hình 4.14 Dashboard tổng quan hệ thống phân tích cảm xúc.....	52
Hình 4.15 Giao diện phân tích theo chủ đề	52
Hình 4.16 Giao diện thống kê cảm xúc trên Confession.....	53
Hình 4.17 Biểu đồ xu hướng cảm xúc – 1	53
Hình 4.18 Biểu đồ xu hướng cảm xúc - 2	53
Hình 4.19 Giao diện phân tích cảm xúc của bài viết.....	54

DANH MỤC BẢNG BIỂU

Bảng 3.1 Ví dụ về dữ liệu đã gán nhãn theo các loại cảm xúc.....	25
Bảng 3.2 Tóm tắt quy trình tiền xử lý dữ liệu văn bản tiếng Việt.....	28
Bảng 4.1 Phân bố dữ liệu của các lớp cảm xúc	38
Bảng 4.2 So sánh hiệu suất của các mô hình trên tập kiểm tra	42
Bảng 4.3 So sánh độ chính xác theo lớp của các mô hình	49
Bảng 4.4 Các ví dụ về dự đoán sai của mô hình PhoBERT	50
Bảng 4.5 So sánh kết quả trích xuất từ và phân tích cảm xúc	51

DANH MỤC VIẾT TẮT

Viết tắt	Giải thích
AI	Artificial Intelligence (Trí tuệ nhân tạo)
API	Application Programming Interface (Giao diện lập trình ứng dụng)
BERT	Bidirectional Encoder Representations from Transformers
GPU	Graphics Processing Unit (Đơn vị xử lý đồ họa)
LDA	Latent Dirichlet Allocation
LSTM	Long Short-Term Memory
NER	Named Entity Recognition (Nhận dạng thực thể có tên)
NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
PhoBERT	PHOneme-based BERT (Mô hình BERT dựa trên âm vị học tiếng Việt)
RNN	Recurrent Neural Network (Mạng nơ-ron hồi quy)
SVM	Support Vector Machine
ViBERT	Vietnamese BERT Model
XLM-RoBERTa	Cross-lingual Language Model - Robustly Optimized BERT Approach

LỜI MỞ ĐẦU

Peter Sondergaard, Phó Chủ tịch Cấp cao kiêm Giám đốc Nghiên cứu Toàn cầu của Gartner, từng nhận định: “Thông tin là dầu mỏ của thế kỷ 21, và phân tích chính là động cơ đốt trong”. Trong bối cảnh chuyển mình từ Công nghiệp 3.0 sang 4.0, khi trí tuệ nhân tạo và dữ liệu ngày càng đóng vai trò then chốt, thông tin thực sự đã trở thành tài nguyên quý giá tựa “vàng đen”, thúc đẩy từng bước phát triển các mô hình ngôn ngữ lớn như ChatGPT, ClaudeAI, Gemini hay mới nhất là Grok. Đồng thời, xu hướng mini-LLM nhẹ gọn xuất hiện với các mô hình như DeepSeek, ChatGPT-o1mini hay Phi4-mini, nhằm vượt qua hạn chế về hạ tầng tính toán và đáp ứng nhu cầu xử lý dữ liệu không lồ mà vẫn đạt được kết quả tốt.

Lấy cảm hứng từ quan điểm này, nghiên cứu của nhóm chúng em tập trung “khai thác mỏ dầu thông tin” từ phản hồi của sinh viên UTC2 trên nền tảng mạng xã hội Facebook, chuyển đổi dữ liệu thô thành những hiểu biết sâu sắc để Ban Giám hiệu kịp thời nắm bắt xu hướng, cải thiện chất lượng đào tạo và nâng cao hiệu quả quản lý. Nhóm nghiên cứu đã tiến hành thu thập và xây dựng bộ dữ liệu phản hồi tiếng Việt chuyên biệt liên quan đến UTC2, rồi thực nghiệm với nhiều mô hình học máy và học sâu, bao gồm SVM, LSTM, ViBERT4news, ViBERT, XLM-RoBERTa và PhoBERT.

Kết quả cho thấy hệ thống không chỉ tự động phân loại chính xác thái độ tích cực, tiêu cực hay trung lập mà còn cung cấp các báo cáo phân tích giúp nhà trường phát hiện kịp thời những vấn đề cấp thiết và điểm mạnh trong hoạt động đào tạo.

Qua đây, chúng em xin trân trọng cảm ơn cô Trần Thị Dung đã tận tình hướng dẫn, đồng hành và chia sẻ nhiều kinh nghiệm quý báu suốt quá trình thực hiện đề tài. Sự tận tâm và góp ý sâu sát của cô đã giúp chúng em vượt qua những thách thức kỹ thuật và hoàn thiện phương pháp luận nghiên cứu. Chúng em cũng chân thành cảm ơn các thầy cô trong Bộ môn đã cung cấp kiến thức nền tảng và định hướng nghiên cứu khoa học, hành trang vô giá cho chúng em trên hành trình sắp tới.

Mặc dù vẫn còn một số hạn chế, chúng em cam kết tiếp tục phát triển, tối ưu hóa hệ thống và mở rộng bộ dữ liệu, mong đóng góp tích cực vào sự phát triển chung của Nhà trường và cộng đồng nghiên cứu. Nội dung báo cáo ngoài việc tham khảo tài liệu, nội dung hoàn toàn mang quan điểm của cá nhân, viết theo văn phong cá nhân. Do đó sẽ không thể tránh khỏi những sai sót không muốn. Rất mong quý hội đồng nghiên cứu tích cực nhận xét để cải thiện.

CHƯƠNG 1: TỔNG QUAN

1.1. Tình hình nghiên cứu

Trong thời đại chuyển đổi số đang diễn ra mạnh mẽ trên toàn cầu, việc khai thác dữ liệu phi cấu trúc để hỗ trợ ra quyết định ngày càng trở nên phổ biến trong nhiều lĩnh vực, đặc biệt là trong giáo dục. Một trong những hướng nghiên cứu quan trọng thuộc lĩnh vực xử lý ngôn ngữ tự nhiên (NLP) là phân tích cảm xúc – kỹ thuật giúp phát hiện và phân loại thái độ, quan điểm, hay cảm xúc của người dùng thông qua văn bản. Hướng nghiên cứu này được xem là nền tảng cho việc cải tiến chất lượng dịch vụ, nâng cao trải nghiệm người học, đồng thời cung cấp các gợi ý chiến lược trong công tác quản lý và đào tạo.

Trên thế giới, các nghiên cứu về phân tích cảm xúc đã được quan tâm từ những năm đầu của thế kỷ 21, với công trình tiêu biểu[4], sử dụng các mô hình học máy truyền thống như Naive Bayes, Maximum Entropy và SVM để phân loại cảm xúc trong các bài đánh giá phim. Trong các năm tiếp theo, nhiều nghiên cứu tiếp tục cải tiến theo hai hướng chính: nâng cao chất lượng đặc trưng đầu vào và phát triển kiến trúc mô hình phân loại. Việc áp dụng các mô hình học sâu như CNN[22] hay LSTM[24] đã giúp mô hình nắm bắt tốt hơn mối quan hệ ngữ nghĩa giữa các từ trong câu. Tuy nhiên, bước ngoặt lớn nhất phải kể đến là sự ra đời của mô hình transformer, tiêu biểu là BERT[7]. BERT và các biến thể như RoBERTa, ALBERT hay XLM-RoBERTa đã đưa NLP lên một tầm cao mới, đặc biệt trong việc hiểu ngữ cảnh hai chiều của ngôn ngữ tự nhiên, góp phần nâng cao độ chính xác trong các bài toán phân tích cảm xúc.

Tuy nhiên, phần lớn các mô hình trên được huấn luyện trên tập dữ liệu chuẩn hóa tiếng Anh, nên khi áp dụng cho các ngôn ngữ khác, đặc biệt là các ngôn ngữ có cấu trúc phức tạp và giàu ngữ nghĩa như tiếng Việt, thường gặp nhiều khó khăn, đặc biệt với văn bản phi chính thống trên mạng xã hội. Để khắc phục điều này, tại Việt Nam, những năm gần đây đã xuất hiện nhiều nghiên cứu nhằm phát triển các mô hình phù hợp hơn với tiếng Việt. Một bước tiến nổi bật là sự ra đời của PhoBERT[11], một mô hình BERT được tiền huấn luyện trên tập dữ liệu tiếng Việt lớn, bao gồm các nguồn như Wikipedia, báo chí và diễn đàn trực tuyến. Đây là mô hình đầu tiên được huấn luyện chuyên biệt cho tiếng Việt, giúp nâng cao đáng kể hiệu quả trong các tác vụ phân tích văn bản.

Một số công trình tiêu biểu trong nước có thể kể đến như nghiên cứu của [30], sử dụng mô hình lai kết hợp HDP và SVM để phân tích cảm xúc theo chủ đề cho văn bản

tiếng Việt với độ chính xác gần 87%. Tuy nhiên, hầu hết các nghiên cứu trong nước hiện nay vẫn chủ yếu tập trung vào dữ liệu chính thống như khảo sát học kỳ, đánh giá môn học, hoặc nhận xét từ các nền tảng thương mại điện tử – vốn được viết theo ngôn ngữ chuẩn. Việc khai thác phản hồi không chính thức từ sinh viên trên mạng xã hội – nơi thể hiện những cảm xúc chân thật, tức thời và sinh động hơn – vẫn chưa được quan tâm đúng mức.

Xuất phát từ thực tế đó, nhóm nghiên cứu của chúng em lựa chọn triển khai một hệ thống phân tích cảm xúc từ các phản hồi tiếng Việt không chính thống của sinh viên, với dữ liệu tập trung vào Trường Đại học Giao thông Vận tải – Phân hiệu tại TP. Hồ Chí Minh (UTC2). Dữ liệu được thu thập từ các nguồn công khai như Diễn đàn nghe sinh viên nói, UTC2 Confession, các fanpage câu lạc bộ và đội nhóm. Sau khi thu thập, dữ liệu được xử lý nhằm loại bỏ nhiễu như ký tự đặc biệt, từ viết tắt, biểu tượng cảm xúc, đồng thời được gán nhãn thủ công theo ba mức độ cảm xúc: tích cực, tiêu cực và trung tính. Đây không chỉ là bộ dữ liệu hữu ích cho nghiên cứu hiện tại mà còn có thể tái sử dụng cho các bài toán khác trong lĩnh vực NLP tiếng Việt.

Về mặt kỹ thuật, nhóm kết hợp giữa các phương pháp học máy truyền thống và mô hình học sâu hiện đại. Ở giai đoạn đầu, nhóm triển khai mô hình SVM và LSTM nhằm tận dụng khả năng ghi nhớ chuỗi thời gian dài của văn bản. Sau đó, nhóm chuyển sang thử nghiệm các mô hình transformer tiền huấn luyện, nổi bật là PhoBERT; bên cạnh đó, nhóm cũng so sánh hiệu năng với ViBERT, XLM-RoBERTa và ViBERT4News. Kết quả bước đầu cho thấy PhoBERT có độ ổn định cao nhất trên tập dữ liệu mạng xã hội tiếng Việt. ViBERT4News đạt hiệu suất cao nhất, tuy nhiên lại có loss trên tập validation và test cao, cho thấy mô hình có dấu hiệu overfitting và chưa thực sự tổng quát hóa tốt trên dữ liệu ngoài tập huấn luyện.

Đồng thời, để phục vụ mục tiêu ứng dụng, nhóm cũng đang phát triển một giao diện trực quan thể hiện kết quả phân tích cảm xúc theo thời gian, theo chủ đề hoặc theo mức độ phổ biến. Hệ thống này giúp nhà trường nắm bắt được xu hướng cảm xúc của sinh viên theo từng học kỳ hoặc theo các sự kiện cụ thể, từ đó hỗ trợ ra quyết định trong việc điều chỉnh nội dung đào tạo, cải tiến dịch vụ sinh viên và tăng cường tương tác giữa nhà trường và người học.

Với bối cảnh hiện nay, đề tài nghiên cứu mang tính cấp thiết cả về mặt khoa học lẫn thực tiễn. Về khoa học, đề tài góp phần mở rộng phạm vi ứng dụng của các mô hình

phân tích cảm xúc tiếng Việt trên dữ liệu phi cấu trúc và phi chuẩn. Về thực tiễn, đề tài cung cấp một công cụ hỗ trợ nhà trường tiếp cận nhanh chóng và chính xác tâm tư, nguyện vọng của sinh viên – yếu tố then chốt trong chiến lược nâng cao chất lượng đào tạo và trải nghiệm học tập trong thời đại số.

1.2. Lý do chọn đề tài

Trong bối cảnh giáo dục đại học hiện đại, chất lượng đào tạo không chỉ được đánh giá qua chương trình giảng dạy, đội ngũ giảng viên hay cơ sở vật chất mà còn thông qua mức độ hài lòng và cảm nhận thực tế của sinh viên – những người trực tiếp trải nghiệm toàn bộ quá trình học tập và sinh hoạt trong môi trường đại học. Việc thu thập, lắng nghe và phản hồi lại ý kiến sinh viên một cách kịp thời, chính xác là một yêu cầu tất yếu nhằm nâng cao chất lượng đào tạo, dịch vụ hỗ trợ và hướng tới sự phát triển bền vững của các cơ sở giáo dục.

Trước đây, các hình thức khảo sát truyền thống như phát phiếu đánh giá giảng viên, khảo sát cuối kỳ hoặc gửi email thu thập ý kiến thường được sử dụng để lấy ý kiến từ sinh viên. Tuy nhiên, theo nhiều nghiên cứu trong và ngoài nước, phương pháp này đang bộc lộ những hạn chế rõ rệt: số lượng phản hồi ít, dữ liệu thu về mang tính hình thức, sinh viên thường không mặn mà tham gia hoặc không chia sẻ đầy đủ quan điểm cá nhân. Bên cạnh đó, thời gian thu thập và xử lý dữ liệu kéo dài khiến cho kết quả khảo sát mất tính thời sự và không phản ánh được những vấn đề nóng đang xảy ra trong thực tế học tập. Một ví dụ cụ thể tại một số trường đại học trong nước cho thấy, tỷ lệ sinh viên điền khảo sát online chỉ dao động quanh mức 30–40%, dẫn đến những kết luận mang tính đại diện thấp và thiếu cơ sở để nhà trường điều chỉnh chính sách kịp thời.

Ngược lại, mạng xã hội – đặc biệt là Facebook – đang nổi lên như một kênh phản ánh trung thực và sống động đời sống sinh viên. Trên các diễn đàn như “UTC2 Confessions”, “Nghe sinh viên nói”, hay fanpage của các khoa, câu lạc bộ tại Trường Đại học Giao thông Vận tải – Phân hiệu tại TP. Hồ Chí Minh (UTC2), sinh viên liên tục chia sẻ ý kiến, cảm xúc, và trải nghiệm cá nhân liên quan đến các vấn đề học tập, giảng dạy, cơ sở vật chất, các quy định nhà trường hoặc các sự kiện sinh viên. Theo thống kê không chính thức, mỗi tuần có hàng chục đến hàng trăm bài viết và bình luận được đăng tải, nhiều trong số đó chứa đựng những thông tin rất giá trị về tâm tư, nguyện vọng và những điều sinh viên mong muốn thay đổi. Điều đáng tiếc là những thông tin này hiện vẫn chưa được khai thác một cách bài bản, hệ thống và hiệu quả, do dữ liệu tồn tại dưới

dạng văn bản tự do (phi cấu trúc), không theo khuôn mẫu, và có nhiều yếu tố đặc thù của ngôn ngữ không chính thức như viết tắt, tiếng lóng, biểu tượng cảm xúc, hoặc sự kết hợp nhiều ngôn ngữ trong cùng một câu.

Trong bối cảnh đó, việc ứng dụng các công nghệ hiện đại như Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP) và học sâu (Deep Learning) để phân tích, trích xuất và phân loại cảm xúc từ các phản hồi của sinh viên trên mạng xã hội là một hướng đi mang tính đột phá. Các mô hình học sâu như LSTM, BERT và các phiên bản tối ưu hóa cho tiếng Việt như PhoBERT hay ViBERT4news đã chứng minh hiệu quả vượt trội trong các nhiệm vụ phân tích cảm xúc và phân loại văn bản tiếng Việt. Những mô hình này có khả năng học ngữ cảnh sâu, xử lý câu có cấu trúc phức tạp và hiểu được ý nghĩa tiềm ẩn sau từng dòng cảm xúc – điều mà các phương pháp truyền thống khó có thể thực hiện.

Trên thế giới, nhiều trường đại học tiên tiến như MIT, Stanford, NUS,... đã và đang triển khai các hệ thống phân tích phản hồi sinh viên trên quy mô lớn bằng NLP để điều chỉnh chiến lược đào tạo, nâng cao sự hài lòng của sinh viên và xây dựng môi trường học tập lấy người học làm trung tâm. Tại Việt Nam, các nghiên cứu trong lĩnh vực này vẫn còn ít, chủ yếu dừng lại ở mức phân tích khảo sát hoặc nghiên cứu học thuật chưa gắn liền với dữ liệu thực tế từ mạng xã hội – nơi phản ánh những dòng cảm xúc chân thực và có giá trị khai thác sâu sắc.

Vì vậy, đề tài "Nghiên cứu thuật toán NLP và ứng dụng vào bài toán phân tích thái độ tích cực, tiêu cực của sinh viên UTC2 trên mạng xã hội Facebook" mang tính cấp thiết cao, không chỉ về mặt khoa học – công nghệ mà còn mang ý nghĩa thiết thực với nhà trường. Bằng việc xây dựng hệ thống có khả năng tự động thu thập, xử lý và phân tích phản hồi từ Facebook, đề tài hướng đến mục tiêu hỗ trợ nhà trường nắm bắt nhanh chóng các vấn đề sinh viên đang quan tâm, từ đó cải tiến chính sách, nâng cao trải nghiệm học tập, thúc đẩy sự hài lòng và gắn bó của sinh viên với nhà trường.

Bên cạnh đó, đề tài còn mở ra hướng phát triển ứng dụng các công nghệ AI và xử lý ngôn ngữ vào bài toán quản lý giáo dục tại Việt Nam – một lĩnh vực đang ngày càng đòi hỏi sự chuyển mình mạnh mẽ trong thời đại chuyển đổi số. Việc triển khai nghiên cứu này không chỉ có ý nghĩa trong phạm vi Trường Đại học Giao thông Vận tải – Phân hiệu tại TP. Hồ Chí Minh, mà còn có thể mở rộng, áp dụng cho các cơ sở giáo

dục khác trong nước có đặc điểm tương tự, từ đó góp phần nâng cao chất lượng giáo dục đại học trên bình diện quốc gia.

1.3. Mục tiêu, nội dung, phương pháp nghiên cứu của đề tài

1.3.1. Mục tiêu nghiên cứu

Mục tiêu chính của đề tài là xây dựng một mô hình phân tích thái độ tích cực và tiêu cực từ các phản hồi của sinh viên UTC2 trên mạng xã hội Facebook, từ đó hỗ trợ nhà trường trong việc đánh giá sự hài lòng của người học và đưa ra các giải pháp cải thiện chất lượng đào tạo. Đề tài không chỉ hướng đến việc áp dụng công nghệ xử lý ngôn ngữ tự nhiên mà còn mong muốn đóng góp vào việc hình thành cơ chế phản hồi sinh viên hiệu quả, linh hoạt và gần với thực tế hơn.

Đầu tiên, nghiên cứu hướng đến việc tìm hiểu và đánh giá các mô hình học sâu hiện đại có khả năng phân tích cảm xúc trong tiếng Việt. Trong đó, mô hình PhoBERT – một biến thể của BERT được huấn luyện chuyên biệt cho ngữ liệu tiếng Việt – sẽ là trọng tâm. Việc lựa chọn PhoBERT xuất phát từ những kết quả thực nghiệm tốt trong các nghiên cứu trước, cũng như khả năng xử lý ngữ nghĩa ngữ cảnh sâu của mô hình này trong tiếng Việt không chính thống, như văn bản từ mạng xã hội.

Tiếp theo, nhóm nghiên cứu sẽ phát triển và huấn luyện mô hình PhoBERT trên tập dữ liệu thu thập từ Facebook, bao gồm các bài viết và bình luận từ sinh viên UTC2. Quá trình này đòi hỏi việc tinh chỉnh mô hình (fine-tuning) để phù hợp với ngữ cảnh cảm xúc trong môi trường giáo dục, đồng thời tối ưu hóa kiến trúc nhằm nâng cao hiệu quả phân loại thái độ tích cực – tiêu cực – trung lập (nếu có).

Một trong những mục tiêu quan trọng khác là đảm bảo độ chính xác và tính khả thi của mô hình khi áp dụng trong thực tế. Mô hình được xây dựng cần đạt độ chính xác cao về mặt kỹ thuật (thông qua các chỉ số như accuracy, F1-score) và đồng thời có khả năng phản ánh đúng tinh thần phản hồi của sinh viên trong từng ngữ cảnh cụ thể. Đây là cơ sở để mô hình có thể được tích hợp vào các hệ thống hỗ trợ ra quyết định trong quản lý giáo dục.

Bên cạnh đó, đề tài cũng đặt mục tiêu cung cấp một bức tranh toàn cảnh và có chiều sâu về mức độ hài lòng của sinh viên đối với các khía cạnh như chương trình đào tạo, đội ngũ giảng viên, cơ sở vật chất, dịch vụ hỗ trợ sinh viên... Thông qua việc trích xuất chủ đề và phân tích cảm xúc tương ứng, đề tài kỳ vọng sẽ hỗ trợ nhà trường trong việc xác định các điểm mạnh cần phát huy cũng như các điểm hạn chế cần cải thiện.

Cuối cùng, nghiên cứu mong muốn đưa ra các đề xuất ứng dụng mô hình vào thực tế, chẳng hạn như tích hợp vào hệ thống khảo sát ý kiến sinh viên, hệ thống cảnh báo sớm về các vấn đề nóng trên mạng xã hội, hoặc xây dựng dashboard trực quan giúp Ban Giám hiệu theo dõi tình hình phản hồi theo thời gian thực.

1.3.2. Nội dung nghiên cứu

Để hiện thực hóa các mục tiêu nêu trên, nội dung nghiên cứu sẽ tập trung vào việc phân tích và xử lý dữ liệu văn bản phi cấu trúc từ mạng xã hội, đặc biệt là các nội dung do sinh viên UTC2 đăng tải hoặc bình luận. Cụ thể, các nội dung nghiên cứu bao gồm:

Trước hết, nhóm nghiên cứu sẽ tiến hành thu thập dữ liệu từ các trang Facebook có liên quan đến sinh viên UTC2, điển hình như các trang confession, hội nhóm sinh viên, fanpage khoa, bộ môn,... Sau khi thu thập, dữ liệu sẽ được xử lý để loại bỏ nhiễu (spam, ký tự đặc biệt, từ viết tắt...) và chuẩn hóa để phù hợp với đầu vào của các mô hình học sâu.

Tiếp theo là bước xây dựng và huấn luyện các mô hình phân tích cảm xúc. Nhóm sẽ áp dụng một số mô hình học sâu và học máy như SVM, LSTM, ViBERT, ViBERT4news, XLM-RoBERTa để so sánh hiệu suất. Tuy nhiên, trọng tâm sẽ đặt vào việc tinh chỉnh và tối ưu hóa PhoBERT – mô hình có tiềm năng cao nhất trong xử lý tiếng Việt không chính thức. Dữ liệu được gán nhãn thủ công (hoặc bán tự động) để phục vụ quá trình huấn luyện.

Sau khi huấn luyện, mô hình sẽ được đánh giá thông qua các chỉ số như độ chính xác (accuracy), độ phủ (recall), độ chính xác (precision), và chỉ số F1. Việc đánh giá này sẽ giúp chọn ra mô hình phù hợp nhất để đưa vào phân tích dữ liệu thực tế.

Giai đoạn tiếp theo là phân tích kết quả. Các phản hồi sau khi được phân loại sẽ được tổng hợp theo chủ đề và đối chiếu với các yếu tố trong môi trường học tập tại UTC2. Việc này không chỉ giúp xác định các chủ đề nổi bật mà còn giúp phát hiện xu hướng cảm xúc của sinh viên theo từng nhóm vấn đề.

Từ những kết quả phân tích, nghiên cứu sẽ đưa ra các khuyến nghị cụ thể như: cải thiện một số dịch vụ sinh viên chưa được đánh giá cao, tăng cường truyền thông nội bộ để giải đáp kịp thời các thắc mắc phổ biến, hoặc phát huy những điểm sáng trong trải nghiệm học tập mà sinh viên đánh giá tích cực.

Cuối cùng, đề tài sẽ đề xuất các hướng ứng dụng thực tiễn của mô hình đã xây dựng. Một số ý tưởng như: xây dựng dashboard theo dõi cảm xúc sinh viên theo thời

gian thực, ứng dụng vào công cụ đánh giá mức độ hài lòng tự động định kỳ, hoặc sử dụng như một công cụ cảnh báo sớm về các vấn đề tiềm ẩn trong môi trường sinh viên cũng sẽ được xem xét và đề xuất.

1.3.3. Phương pháp nghiên cứu

Để đạt được mục tiêu nghiên cứu, nhóm lựa chọn cách tiếp cận định lượng kết hợp với các kỹ thuật phân tích dữ liệu hiện đại trong lĩnh vực xử lý ngôn ngữ tự nhiên (NLP). Phương pháp nghiên cứu được xây dựng theo quy trình gồm nhiều bước liên tiếp, từ thu thập dữ liệu đến phân tích và diễn giải kết quả. Cụ thể:

Nghiên cứu thu thập dữ liệu thứ cấp từ các nền tảng mạng xã hội nơi sinh viên Trường Đại học Giao thông Vận tải – Phân hiệu tại TP. Hồ Chí Minh (UTC2) thường xuyên tương tác. Nguồn dữ liệu bao gồm các bài viết và bình luận từ fanpage UTC2, các nhóm sinh viên, diễn đàn “Nghe sinh viên nói” và trang “UTC2 Confession”. Công cụ chính được sử dụng là web scraping và API, kết hợp với kỹ thuật lọc nhằm thu thập có chọn lọc các phản hồi liên quan đến trải nghiệm học tập tại trường.

Dữ liệu văn bản sau khi thu thập được xử lý thông qua các kỹ thuật tiền xử lý NLP để chuẩn hóa đầu vào cho mô hình học sâu. Quy trình bao gồm loại bỏ ký tự đặc biệt, chuẩn hóa chính tả, tách từ bằng thư viện Vietnamese Tokenizer, và mã hóa văn bản theo định dạng tương thích với các mô hình học sâu sẽ sử dụng.

Để thực hiện phân tích cảm xúc, nghiên cứu triển khai các mô hình học sâu và học máy, trong đó ưu tiên mô hình PhoBERT – biến thể của BERT được tối ưu hóa cho tiếng Việt. Các mô hình như RNN, LSTM, ViBERT và XLM-RoBERTa cũng được áp dụng để đánh giá so sánh hiệu năng. Quá trình huấn luyện sử dụng bộ dữ liệu được phân chia theo tỷ lệ huấn luyện – kiểm thử – đánh giá (70%-15%-15%), kết hợp kỹ thuật điều chỉnh siêu tham số nhằm tối ưu hóa hiệu suất mô hình.

Hiệu năng của các mô hình được đánh giá khách quan thông qua các chỉ số tiêu chuẩn trong phân loại văn bản như accuracy, precision, recall, và F1-score. Việc so sánh hiệu suất giữa các mô hình giúp xác định phương pháp phù hợp nhất với đặc thù dữ liệu phản hồi sinh viên UTC2.

Sau khi chọn được mô hình tối ưu, toàn bộ dữ liệu được phân tích cảm xúc và phân loại thành thái độ tích cực hoặc tiêu cực theo từng nhóm chủ đề (chương trình học, cơ sở vật chất, đội ngũ giảng viên...). Kỹ thuật trực quan hóa dữ liệu được ứng dụng để minh họa các xu hướng cảm xúc và mức độ hài lòng của sinh viên.

Dựa trên kết quả phân tích dữ liệu, nghiên cứu xác định các khía cạnh được sinh viên đánh giá cao cũng như các vấn đề tồn tại cần cải thiện. Từ đó, đưa ra các khuyến nghị cụ thể nhằm nâng cao chất lượng đào tạo và trải nghiệm học tập tại UTC2.

Cuối cùng, nghiên cứu xem xét khả năng ứng dụng mô hình vào thực tế, chẳng hạn như phát triển hệ thống giám sát tự động các phản hồi trên mạng xã hội hoặc xây dựng dashboard hỗ trợ Ban Giám hiệu trong việc ra quyết định dựa trên phân tích cảm xúc từ sinh viên.

1.4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là các phản hồi, ý kiến và đánh giá của sinh viên Trường Đại học Giao thông Vận tải – Phân hiệu tại TP. Hồ Chí Minh (UTC2) liên quan đến trải nghiệm học tập tại trường. Những phản hồi này có thể xuất hiện dưới dạng bình luận, bài đăng, hoặc chia sẻ trên các nền tảng mạng xã hội, đặc biệt là Facebook – nơi sinh viên thường xuyên trao đổi, bày tỏ quan điểm cá nhân. Nội dung phản hồi tập trung vào các khía cạnh như: chất lượng giảng dạy, chương trình đào tạo, cơ sở vật chất, dịch vụ hỗ trợ sinh viên, và các yếu tố liên quan đến môi trường học tập nói chung.

Phạm vi nghiên cứu được xác định cụ thể như sau:

Phạm vi về không gian: Nghiên cứu chỉ tập trung vào các dữ liệu phản hồi từ sinh viên đang theo học tại Trường Đại học Giao thông Vận tải – Phân hiệu tại TP. Hồ Chí Minh. Các phản hồi từ sinh viên các cơ sở khác của trường sẽ không được đưa vào phân tích.

Phạm vi về thời gian: Dữ liệu được thu thập trong khoảng thời gian trải dài từ năm 2013 cho đến nay. Khoảng thời gian này đảm bảo dữ liệu phản ánh các phản hồi đầy đủ và tổng quát nhất.

Phạm vi về nội dung: Nghiên cứu tập trung phân tích các phản hồi liên quan trực tiếp đến các vấn đề học tập tại trường, cụ thể gồm: chất lượng giảng dạy, nội dung chương trình đào tạo, thái độ và năng lực của giảng viên, điều kiện cơ sở vật chất (phòng học, thư viện, thiết bị học tập), và dịch vụ hỗ trợ sinh viên. Những phản hồi mang tính cá nhân không liên quan đến hoạt động học tập hoặc nằm ngoài phạm vi hoạt động của nhà trường sẽ được hạn chế để đảm bảo tính trọng tâm và khách quan trong nghiên cứu.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về bài toán phân tích cảm xúc (Sentiment Analysis)

2.1.1. Khái niệm và phạm vi ứng dụng

Phân tích cảm xúc là một nhánh quan trọng của xử lý ngôn ngữ tự nhiên, tập trung vào việc tự động phát hiện, trích xuất và phân loại ý kiến, thái độ hoặc cảm xúc được thể hiện trong văn bản [1,3]. Trong thời đại bùng nổ dữ liệu, khi hàng triệu đánh giá, bình luận và bài đăng trên mạng xã hội được tạo ra mỗi ngày, phân tích cảm xúc trở thành công cụ không thể thiếu để khai thác những thông tin giá trị mà con người không thể xử lý thủ công.

Theo Prof. Bing Liu một chuyên gia hàng đầu trong lĩnh vực khai phá dữ liệu và phân tích ý kiến, phân tích cảm xúc không chỉ dừng lại ở việc gắn nhãn tích cực hay tiêu cực cho văn bản, mà còn giúp nắm bắt xu hướng dư luận, dự đoán phản ứng thị trường, và hỗ trợ ra quyết định trong các lĩnh vực như marketing, chính trị, y tế, giáo dục [1]. Các hệ thống hiện đại thường kết hợp nhiều phương pháp, từ phương pháp dựa trên từ điển (lexicon-based), học máy, đến học sâu với các mô hình nổi bật như BERT, LSTM và Transformer [2].

Trong nghiên cứu của chúng em, phân tích cảm xúc được áp dụng để phân loại thái độ của sinh viên Trường Đại học Giao thông vận tải phân hiệu tại TP.HCM(UTC2) trên các bài đăng và bình luận Facebook. Việc này mang lại giá trị lớn, giúp nhà trường nắm bắt kịp thời trải nghiệm học tập, mức độ hài lòng và các vấn đề nổi bật, từ đó điều chỉnh chính sách và cải thiện chất lượng giáo dục.

2.1.2. Các cấp độ phân tích cảm xúc

Theo Assoc. Prof. Bo Pang và Prof. Lillian Lee (Cornell University, USA), phân tích cảm xúc có thể được thực hiện ở ba cấp độ chính: cấp độ văn bản, cấp độ câu, và cấp độ khía cạnh [4].

Ở cấp độ văn bản, hệ thống xem toàn bộ văn bản như một thực thể thống nhất để xác định thái độ chung. Cách tiếp cận này phù hợp khi người viết thể hiện ý kiến rõ ràng, nhất quán, nhưng gặp hạn chế nếu nội dung chứa nhiều ý kiến trái chiều hoặc đề cập nhiều chủ đề.

Ở cấp độ câu, hệ thống phân tích từng câu riêng biệt, giúp phát hiện các ý kiến phân mảnh trong văn bản dài. Điều này hữu ích khi người viết vừa khen vừa chê trong cùng một nội dung.

Ở cấp độ khía cạnh, phân tích cảm xúc tập trung vào các yếu tố cụ thể được đề cập trong văn bản, như chất lượng giảng viên, cơ sở vật chất, hoặc chương trình học. Đây là cấp độ giàu thông tin nhất, nhưng cũng đòi hỏi công nghệ phức tạp để trích xuất đúng các khía cạnh và gán nhãn cảm xúc chính xác [5].

Trong nghiên cứu của chúng em, nhóm chủ yếu tập trung vào cấp độ văn bản và câu do hạn chế về dữ liệu và năng lực mô hình. Tuy nhiên, mục tiêu dài hạn là mở rộng sang phân tích khía cạnh để cung cấp báo cáo chuyên sâu hơn, hỗ trợ nhà trường đưa ra giải pháp cải thiện cụ thể.

2.1.3. Các thách thức trong phân tích cảm xúc trong tiếng Việt

Theo Dr. Xuan-Tung Vu (Viện Công nghệ Thông tin, Viện Hàn lâm Khoa học và Công nghệ Việt Nam), người phát triển công cụ VnCoreNLP, phân tích ngôn ngữ tiếng Việt cần các phương pháp riêng, không thể áp dụng trực tiếp từ các mô hình xây dựng cho tiếng Anh [6]. Tiếng Việt là ngôn ngữ đơn lập, có cấu trúc ngữ pháp, cú pháp và ngữ nghĩa khác biệt, đòi hỏi phải điều chỉnh kỹ thuật khi xử lý.

Một thách thức lớn là thiếu dữ liệu gán nhãn cho tiếng Việt, khiến việc huấn luyện các mô hình học máy và học sâu gặp khó khăn. Bên cạnh đó, ngôn ngữ trên mạng xã hội thường không tuân thủ chuẩn mực, chứa nhiều từ viết tắt, biểu tượng cảm xúc, lỗi chính tả, và tiếng lóng, làm phức tạp hóa quá trình tiền xử lý.

Ngoài ra, việc phát hiện các yếu tố ngữ nghĩa phức tạp như châm biếm, mỉa mai, ẩn dụ đòi hỏi mô hình không chỉ hiểu ngôn ngữ mà còn phải nắm bắt được ngữ cảnh và văn hóa. Ngay cả các mô hình học sâu tiên tiến như BERT[7] cũng gặp hạn chế khi áp dụng cho các ngôn ngữ ít tài nguyên như tiếng Việt. Thêm vào đó, sự đa dạng phương ngữ giữa các vùng miền đòi hỏi hệ thống phải đủ linh hoạt để đảm bảo độ chính xác trên phạm vi toàn quốc.

2.2 Tổng quan về xử lý ngôn ngữ tự nhiên


Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP) là lĩnh vực giao thoa giữa khoa học máy tính, trí tuệ nhân tạo và ngôn ngữ học, nhằm giúp máy tính hiểu, diễn giải và sinh ngôn ngữ của con người. Từ thập niên 1950 (khi “Turing Test” được giới thiệu) đến nay, NLP phát triển mạnh mẽ, đặc biệt sau cuộc cách mạng học sâu. Theo

Prof. Daniel Jurafsky, NLP không chỉ dừng ở phân tích cú pháp hay ngữ nghĩa, mà còn hướng tới việc nắm bắt ý định, cảm xúc và tri thức hàm ẩn trong ngôn từ, mở đường cho các ứng dụng như dịch máy, trợ lý ảo, tóm tắt văn bản và phát hiện tin giả [8].

2.2.1. Khái niệm

NLP tìm cách mô hình hóa ngôn ngữ thành tín hiệu số để thuật toán xử lý. Assoc. Prof. Christopher Manning chỉ ra quy trình chuẩn gồm: (i) thu thập–làm sạch dữ liệu, (ii) biến đổi văn bản sang biểu diễn số (tokenization, embedding), (iii) huấn luyện mô hình học máy/học sâu, và (iv) đánh giá–triển khai [9]. Việc chuyển từ đặc trưng thủ công sang học sâu đã làm giảm phụ thuộc vào tri thức chuyên gia, đồng thời nâng cao độ chính xác trên nhiều tác vụ ngôn ngữ.

NLP Pipeline



Hình 2.1 Sơ đồ luồng quy trình xử lý ngôn ngữ tự nhiên


2.2.2. Đặc thù của tiếng Việt trong NLP

Tiếng Việt là ngôn ngữ đơn lập: khoảng trắng phân tách tiếng chữ không phân tách từ, nên bước tách từ (word segmentation) trở thành mắt xích tối quan trọng trong mọi pipeline xử lý ngôn ngữ tự nhiên. Hệ thống sáu thanh điệu cùng hiện tượng đồng âm dị nghĩa khiến tác vụ gán nhãn từ loại và nhận dạng thực thể khó khăn hơn, vì mô hình phải vừa giữ nguyên dấu vừa giải quyết đa nghĩa phụ thuộc ngữ cảnh [9]. Thêm vào đó, sự đa dạng phương ngữ Bắc-Trung-Nam cùng tình trạng thiếu hụt corpora gán nhãn quy mô lớn làm tăng nguy cơ suy giảm độ chính xác khi mô hình được huấn luyện trên một vùng và suy diễn sang vùng khác [10]. Ngoài thách thức kỹ thuật, tiếng Việt còn giàu thành ngữ, lối nói châm biếm và hàm ý văn hóa; để giải mã đúng sắc thái, hệ thống cần khả năng hiểu ngữ dụng sâu – điều đặc biệt khó đối với các ngôn ngữ ít tài nguyên [12]. Cuối cùng, các nghiên cứu gần đây khẳng định rằng kết hợp quy trình tiền xử lý tinh chỉnh (chuẩn hóa ký tự, tách từ, xử lý tiếng lóng) với embedding ngữ cảnh

sâu như PhoBERT[11] giúp nâng cao đáng kể hiệu năng trên các tác vụ phân loại và gán nhãn tiếng Việt.

2.2.3. Tiền xử lý văn bản tiếng Việt

Quy trình tiền xử lý quyết định chất lượng đầu ra của mọi tác vụ NLP tiếng Việt. Bước đầu là chuẩn hoá ký tự, tách câu, tách tiếng và tách từ bằng công cụ như VnCoreNLP hoặc RDRSegmenter. Việc loại bỏ stop-words cần cân nhắc vì nhiều hư từ tiếng Việt mang thông tin ngữ dụng. Văn bản sau đó được xử lý tiếng lóng, viết tắt – vốn phổ biến trên mạng xã hội – rồi chuyển sang chữ thường và gỡ ký hiệu thừa. Cuối cùng, vector hoá bằng Word2Vec, FastText hoặc embedding từ mô hình tiền huấn luyện như PhoBERT biến chuỗi ký tự thành biểu diễn số. Dr. Dat Quoc Nguyen cho thấy kết hợp kỹ lưỡng tiền xử lý với embedding ngữ cảnh sâu giúp tăng đáng kể độ chính xác cho bài toán phân loại, gán nhãn và sinh ngôn ngữ tiếng Việt [11]. Bên cạnh đó, Dr. Xuan-Tung Vu khẳng định các thành phần của bộ công cụ VnCoreNLP[6] – gồm tách từ, gán nhãn từ loại, phân tích câu phụ thuộc – đóng vai trò nền tảng cho hầu hết pipeline NLP tiếng Việt hiện nay .



Hình 2.2. Quy trình tiền xử lý dữ liệu văn bản trong xử lý ngôn ngữ tự nhiên

2.3. Học máy trong phân tích cảm xúc

2.3.1. Biểu diễn văn bản

Trong giai đoạn sơ khai của nghiên cứu về phân tích cảm xúc, việc chuyển đổi văn bản tự nhiên thành các biểu diễn số học mà các thuật toán học máy có thể hiểu và xử lý là một bước nền tảng. Các phương pháp biểu diễn văn bản truyền thống đóng vai trò quan trọng trong việc đặt nền móng cho các nghiên cứu sau này:

Mô hình túi từ (Bag-of-Words - BoW): Đây là một trong những phương pháp biểu diễn văn bản đơn giản nhất, tập trung vào tần suất xuất hiện của từng từ trong một văn bản. Một văn bản được biểu diễn bởi một vector, trong đó mỗi chiều tương ứng với một từ duy nhất trong toàn bộ vốn từ vựng của tập dữ liệu, và giá trị tại chiều đó thể hiện số lần từ đó xuất hiện trong văn bản. BoW bỏ qua hoàn toàn thứ tự và cấu trúc ngữ pháp của các từ, coi mỗi văn bản như một “túi” chứa các từ.

TF-IDF (Term Frequency-Inverse Document Frequency): Để khắc phục nhược điểm của BoW là coi tất cả các từ đều quan trọng như nhau, TF-IDF được giới thiệu. Phương pháp này gán trọng số cho mỗi từ trong văn bản dựa trên tần suất xuất hiện của nó trong văn bản đó (TF) và tần suất nghịch đảo của nó trong toàn bộ tập dữ liệu (IDF). Những từ xuất hiện nhiều trong một văn bản cụ thể nhưng ít xuất hiện trong các văn bản khác sẽ có trọng số cao hơn, phản ánh tầm quan trọng của chúng đối với nội dung của văn bản đó.

2.3.2. Các thuật toán học máy truyền thống

Sau khi văn bản được biểu diễn dưới dạng vector số, các thuật toán học máy truyền thống đã được áp dụng rộng rãi để xây dựng các mô hình phân loại cảm xúc. Những thuật toán này, mặc dù có những hạn chế nhất định trong việc xử lý ngôn ngữ tự nhiên phức tạp, nhưng vẫn đóng vai trò quan trọng trong việc cung cấp các giải pháp hiệu quả cho nhiều bài toán phân tích cảm xúc:

Máy vector hỗ trợ (Support Vector Machines - SVM) [15]: Là một mô hình học có giám sát mạnh mẽ, SVM tìm kiếm một siêu phẳng tối ưu trong không gian đặc trưng để phân tách các mẫu dữ liệu thuộc các lớp khác nhau với biên độ lớn nhất. Trong nghiên cứu về ViBERT [12], việc so sánh hiệu suất với SVM trên bộ dữ liệu UIT-VSFC [27] đã làm nổi bật khả năng của các mô hình dựa trên Transformer trong việc nắm bắt các đặc trưng ngôn ngữ phức tạp hơn so với các mô hình tuyến tính như SVM.

Naive Bayes [16]: Dựa trên định lý Bayes, thuật toán này tính toán xác suất một văn bản thuộc về một lớp cảm xúc cụ thể dựa trên xác suất của từng từ trong văn bản đó thuộc về lớp đó, giả định rằng các từ là độc lập với nhau trong ngữ cảnh của lớp. Mặc dù giả định này thường không đúng trong ngôn ngữ tự nhiên, Naive Bayes vẫn là một thuật toán đơn giản và hiệu quả cho nhiều tác vụ phân loại văn bản.

Hồi quy Logistic (Logistic Regression) [17]: Là một mô hình tuyến tính sử dụng hàm sigmoid để mô hình hóa xác suất của một biến phân loại. Trong phân tích cảm xúc, hồi quy logistic có thể được sử dụng để dự đoán xác suất một văn bản mang cảm xúc tích cực, tiêu cực hoặc trung tính dựa trên các đặc trưng được trích xuất từ văn bản.

Cây quyết định (Decision Trees) [18] và Rừng ngẫu nhiên (Random Forests) [19]: Cây quyết định xây dựng một cấu trúc cây phân cấp để đưa ra quyết định phân loại dựa trên các luật được học từ dữ liệu. Rừng ngẫu nhiên là một tập hợp của nhiều cây quyết

định, thường cho hiệu suất tốt hơn và ít bị overfitting hơn so với một cây quyết định đơn lẻ.

Mạng nơ-ron hồi quy (RNN) [23] và Mạng bộ nhớ dài-ngắn hạn (LSTM) [24]: Mặc dù thường được xem là các mô hình học sâu, các kiến trúc RNN cơ bản và LSTM đã được sử dụng trong phân tích cảm xúc trước sự phổ biến của Transformer [26]. LSTM, với khả năng xử lý các phụ thuộc dài hạn trong chuỗi văn bản, đã cho thấy những cải thiện so với các mô hình học máy truyền thống trong việc nắm bắt ngữ cảnh. Tuy nhiên, nghiên cứu về ViBERT đã chứng minh rằng các mô hình dựa trên Transformer có thể vượt trội hơn cả LSTM trong việc phân tích cảm xúc tiếng Việt.

2.3.3. Ưu nhược điểm của phương pháp học máy truyền thống

Ưu điểm:

Tính dễ hiểu và khả năng diễn giải: Các mô hình như Naive Bayes, cây quyết định và hồi quy logistic thường dễ hiểu và cho phép phân tích tầm quan trọng của các đặc trưng trong việc đưa ra dự đoán.

Yêu cầu dữ liệu ít hơn: So với các mô hình học sâu phức tạp, các thuật toán học máy truyền thống thường hoạt động tốt với lượng dữ liệu huấn luyện nhỏ hơn.

Tính hiệu quả cho các tác vụ đơn giản: Đối với các bài toán phân tích cảm xúc không quá phức tạp về ngữ cảnh và sắc thái, các mô hình này có thể cung cấp hiệu suất chấp nhận được với chi phí tính toán thấp hơn.

Nhược điểm:

Hạn chế trong việc nắm bắt ngữ cảnh: Các phương pháp biểu diễn văn bản như BoW và TF-IDF không giữ được thông tin về thứ tự và ngữ nghĩa của từ, dẫn đến việc các mô hình học máy truyền thống khó khăn trong việc hiểu được các mối quan hệ phức tạp và sự phụ thuộc xa trong câu.

Phụ thuộc vào đặc trưng thủ công: Hiệu suất của các mô hình này phụ thuộc rất nhiều vào chất lượng của các đặc trưng được trích xuất từ văn bản. Việc thiết kế các đặc trưng hiệu quả đòi hỏi kiến thức chuyên môn về ngôn ngữ và có thể tốn nhiều thời gian.

Khả năng khái quát hóa hạn chế: Các mô hình học máy truyền thống có thể gặp khó khăn trong việc khái quát hóa sang các loại văn bản hoặc miền dữ liệu khác nhau nếu các đặc trưng được thiết kế không phù hợp.

2.4. Học sâu trong phân tích cảm xúc

Sự phát triển mạnh mẽ của học sâu đã mở ra một kỷ nguyên mới trong lĩnh vực xử lý ngôn ngữ tự nhiên, mang lại những tiến bộ đáng kể trong các tác vụ phức tạp như phân tích cảm xúc. Các kiến trúc mạng nơ-ron sâu có khả năng tự động học các biểu diễn văn bản phong phú và nắm bắt ngữ cảnh một cách hiệu quả hơn so với các phương pháp truyền thống.

2.4.1. Mạng nơ-ron tích chập cho xử lý văn bản

Mạng nơ-ron tích chập (CNNs) [22], ban đầu được thiết kế cho xử lý ảnh, đã được chứng minh là hiệu quả trong việc trích xuất các đặc trưng cục bộ quan trọng từ văn bản, chẳng hạn như các n-gram (chuỗi n từ) và các mẫu ký tự có ý nghĩa cảm xúc. Các bộ lọc tích chập (convolutional filters) trượt trên các embedding của từ để phát hiện các mẫu này, giúp mô hình hiểu được các cụm từ mang tính biểu cảm.

2.4.2. Mạng nơ-ron hồi quy (RNN)

Mạng nơ-ron hồi quy (RNNs) [23] được thiết kế đặc biệt để xử lý dữ liệu tuần tự như văn bản. Chúng duy trì một trạng thái ẩn (hidden state) để lưu trữ thông tin về các phần tử trước đó trong chuỗi, cho phép mô hình học được các phụ thuộc theo thời gian. Tuy nhiên, RNN truyền thống gặp khó khăn trong việc học các phụ thuộc dài hạn do vấn đề vanishing gradient.

2.4.3. Mạng bộ nhớ dài-ngắn hạn (LSTM)

Mạng bộ nhớ dài-ngắn hạn (LSTMs) [24] là một biến thể tiên tiến của RNN, được trang bị các cơ chế cổng (gate) phức tạp (input gate, forget gate, output gate) để kiểm soát luồng thông tin vào và ra khỏi bộ nhớ của tế bào. Điều này cho phép LSTM học và duy trì thông tin quan trọng qua các khoảng thời gian dài hơn trong chuỗi văn bản, giải quyết hiệu quả vấn đề phụ thuộc dài hạn và cải thiện khả năng nắm bắt ngữ cảnh.

2.4.4. Cơ chế Attention và Self-Attention

Cơ chế Attention [26] cho phép mô hình tập trung vào các phần quan trọng nhất của chuỗi đầu vào khi đưa ra dự đoán cho một phần cụ thể của đầu ra. Thay vì xử lý toàn bộ chuỗi đầu vào một cách đồng đều, attention cho phép mô hình gán trọng số khác nhau cho các từ hoặc token khác nhau dựa trên mức độ liên quan của chúng đến phần đang được xử lý. Cơ chế Self-Attention là một dạng đặc biệt của attention, cho phép mô hình học được mối quan hệ giữa các từ khác nhau trong cùng một câu bằng cách tính toán sự tương tác trực tiếp giữa tất cả các cặp từ, bất kể vị trí của chúng.

2.4.5. Mô hình Transformer

Kiến trúc Transformer đã đánh dấu một bước ngoặt lớn trong lĩnh vực NLP. Thay vì sử dụng các lớp hồi quy, Transformer dựa hoàn toàn vào cơ chế self-attention để mô hình hóa các mối quan hệ giữa các từ trong một chuỗi. Kiến trúc này cho phép xử lý song song các phần của chuỗi đầu vào, giúp tăng tốc độ huấn luyện và khả năng xử lý các chuỗi dài. Transformer đã chứng minh được hiệu quả vượt trội trong nhiều tác vụ NLP, bao gồm cả phân tích cảm xúc, và là nền tảng cho sự phát triển của các mô hình ngôn ngữ lớn như BERT.

2.4.6. BERT và các phiên bản của BERT cho tiếng Việt

BERT (Bidirectional Encoder Representations from Transformers) [7] là một mô hình ngôn ngữ dựa trên kiến trúc Transformer, được huấn luyện trước trên một lượng lớn dữ liệu văn bản không nhãn bằng cách sử dụng hai nhiệm vụ chính: Masked Language Modeling (MLM) và Next Sentence Prediction (NSP). Quá trình huấn luyện trước này giúp BERT học được các biểu diễn ngữ cảnh sâu sắc của từ, có thể được tinh chỉnh (fine-tune) hiệu quả cho các tác vụ NLP cụ thể với lượng dữ liệu nhãn nhỏ hơn, bao gồm cả phân tích cảm xúc.

Sự thành công của BERT đã thúc đẩy việc phát triển các phiên bản BERT đặc biệt cho tiếng Việt, nhằm tận dụng các đặc trưng ngôn ngữ độc đáo của tiếng Việt và cải thiện hiệu suất trong các tác vụ NLP tiếng Việt:

ViBERT [12]: Nhận thấy tầm quan trọng của một mô hình ngôn ngữ mạnh mẽ cho tiếng Việt, nhóm nghiên cứu tại Đại học Bách khoa Hà Nội đã phát triển ViBERT. Mô hình này kế thừa kiến trúc Transformer hai chiều của BERT và được huấn luyện trên một tập dữ liệu tiếng Việt lớn (20GB) bao gồm Wikipedia tiếng Việt, báo điện tử và diễn đàn giáo dục. Bên cạnh đó, ViBERT còn được tối ưu hóa cho tiếng Việt thông qua việc sử dụng WordPiece tokenizer với bộ từ vựng 30.000 tokens và tích hợp khả năng xử lý các đặc trưng ngôn ngữ như từ ghép, chuẩn hóa phương ngữ và mở rộng từ viết tắt. Kết quả đánh giá trên bộ dữ liệu UIT-VSFC đã chứng minh hiệu quả của những cải tiến này, với ViBERT đạt được F1-score vượt trội so với các mô hình truyền thống.

XLM-RoBERTa [28]: Là một mô hình ngôn ngữ đa ngôn ngữ được phát triển bởi Facebook AI Research, XLM-RoBERTa dựa trên kiến trúc RoBERTa, một phiên bản được tối ưu hóa của BERT. Điểm nổi bật của XLM-RoBERTa là khả năng học biểu diễn ngôn ngữ trên quy mô lớn cho 100 ngôn ngữ, bao gồm cả tiếng Việt (20GB dữ liệu chất

lượng cao). Mặc dù được huấn luyện đa ngôn ngữ, XLM-RoBERTa vẫn cho thấy hiệu suất ấn tượng trên các tác vụ NLP tiếng Việt, đặc biệt là khả năng khái quát hóa tốt trên các tập dữ liệu nhỏ, như đã được ghi nhận trong nghiên cứu của Nguyen et al. (2021) với độ chính xác 86.4% trên UIT-VSFC.

PhoBERT: Được phát triển bởi VinAI Research, PhoBERT là một mô hình BERT chuyên biệt cho tiếng Việt với một đặc điểm nổi bật là sử dụng đơn vị token hóa ở cấp độ âm tiết (syllable-level), một cách tiếp cận phù hợp với đặc tính đơn lập và giàu thanh điệu của tiếng Việt. PhoBERT đã trải qua quá trình phát triển với việc mở rộng đáng kể quy mô dữ liệu huấn luyện, đặc biệt là phiên bản v2 với 140GB dữ liệu, bao gồm cả dữ liệu lớn từ OSCAR-2301 và dữ liệu mạng xã hội đã được làm sạch. Nghiên cứu của bạn đã lựa chọn phiên bản PhoBERT-base-v2 do những cải tiến về độ phủ từ vựng (tăng 15%) và hiệu suất trên các tác vụ phân tích cảm xúc (cải thiện 2.3% F1-score), cũng như khả năng xử lý tốt hơn ngôn ngữ mạng xã hội, điều này rất quan trọng cho việc phân tích thái độ của sinh viên UTC2.

CHƯƠNG 3: PHƯƠNG PHÁP PHÂN TÍCH CẢM XÚC ĐỀ XUẤT


3.1. Tổng quan về phương pháp phân tích cảm xúc đề xuất

Hệ thống phân tích cảm xúc đề xuất trong nghiên cứu này được thiết kế dựa trên một quy trình toàn diện, tận dụng những tiến bộ gần đây trong lĩnh vực học sâu và xử lý ngôn ngữ tự nhiên, đặc biệt là các mô hình đã được chứng minh hiệu quả với ngữ liệu tiếng Việt. Hệ thống của chúng em được xây dựng theo kiến trúc đa tầng với sự tích hợp các công nghệ tiên tiến, nhằm giải quyết một cách hiệu quả các thách thức trong việc phân tích cảm xúc từ dữ liệu mạng xã hội - một nguồn dữ liệu phi chuẩn với nhiều đặc thù ngôn ngữ phức tạp.

Kiến trúc tổng thể của hệ thống được thể hiện trong Hình 3.1. Quy trình bắt đầu từ việc thu thập dữ liệu từ các trang Facebook liên quan đến UTC2, tiếp theo là giai đoạn gán nhãn thủ công dựa trên các tiêu chí được thiết kế kỹ lưỡng. Sau đó, dữ liệu được tiền xử lý qua nhiều bước để đảm bảo chất lượng, tính nhất quán và phù hợp với đặc thù của mô hình học sâu. Tiếp đến là giai đoạn huấn luyện và tinh chỉnh mô hình PhoBERT - một mô hình transformer được tối ưu hóa cho tiếng Việt, kết hợp với một số lớp mạng nơ-ron bổ sung để phục vụ nhiệm vụ phân loại cảm xúc. Cuối cùng, hệ thống thực hiện phân tích cảm xúc trên dữ liệu mới và trực quan hóa kết quả thông qua một dashboard tương tác, cung cấp những phân tích chi tiết về xu hướng cảm xúc của sinh viên theo thời gian và theo chủ đề.

Sự khác biệt và điểm mạnh của hệ thống được đề xuất so với các phương pháp truyền thống nằm ở khả năng tích hợp kiến trúc transformer hiện đại đã được tiền huấn luyện đặc biệt cho tiếng Việt (PhoBERT) với các phương pháp xử lý dữ liệu được tối ưu hóa cho ngữ liệu mạng xã hội. Quy trình này không chỉ có khả năng xử lý hiệu quả các đặc thù của tiếng Việt trên mạng xã hội như từ lóng, biểu tượng cảm xúc, từ viết tắt mà còn có thể nắm bắt ngữ cảnh và ngữ nghĩa trong các câu ngắn - một thách thức lớn với các mô hình phân tích cảm xúc truyền thống.

Trong các phần tiếp theo, chúng em sẽ trình bày chi tiết về từng giai đoạn trong quy trình phân tích cảm xúc đề xuất, từ thu thập dữ liệu đến triển khai hệ thống thực tế.



Hình 3.1 Kiến trúc tổng thể của hệ thống phân tích cảm xúc

3.2. Chi tiết các khối trong hệ thống

3.2.1. Thu thập dữ liệu

Trong nghiên cứu này, nguồn dữ liệu chính được thu thập từ các nền tảng mạng xã hội Facebook liên quan đến Trường Đại học Giao thông Vận tải – Phân hiệu tại TP.HCM (UTC2), bao gồm các fanpage, nhóm và diễn đàn trao đổi của sinh viên. Nhằm đảm bảo tính toàn diện và đại diện cho nhiều góc nhìn khác nhau, chúng em đã lựa chọn các nguồn dữ liệu đa dạng như sau:

Fanpage UTC2 Confessions: Đây là nơi sinh viên thường chia sẻ ẩn danh về trải nghiệm học tập và sinh hoạt tại trường, mang tính chân thực và cảm xúc cao.

Diễn đàn Nghe sinh viên nói: Kênh trao đổi chính thức giữa sinh viên và nhà trường, nơi sinh viên thường đưa ra các góp ý, thắc mắc và kiến nghị.

Các nhóm/fanpage của các khoa và câu lạc bộ: Nơi sinh viên trao đổi thông tin liên quan đến học thuật, hoạt động ngoại khóa và các sự kiện của trường.

Các bài đăng và bình luận công khai của sinh viên UTC2: Bao gồm các thảo luận và phản hồi về các vấn đề liên quan đến nhà trường như học phí, lịch học, cơ sở vật chất, chất lượng giảng dạy....

Quy trình thu thập dữ liệu được thực hiện chủ yếu thông qua phương pháp tự động với sự hỗ trợ của nền tảng Apify – một công cụ chuyên dùng để xây dựng và triển khai các tác vụ thu thập dữ liệu từ các trang web. Apify cho phép gửi các yêu cầu truy vấn (request) đến máy chủ của Facebook, từ đó trích xuất thông tin từ các trang và nhóm công khai đã được xác định. Dữ liệu phản hồi thường ở định dạng JSON, từ đó nhóm tiến hành xử lý và trích xuất các thông tin cần thiết như: nội dung bài viết, tổng số bình luận, lượt cảm xúc, số lượt chia sẻ và thời gian đăng tải.

Nhờ tận dụng các tính năng có sẵn của Apify, quá trình thu thập dữ liệu trở nên hiệu quả, ổn định và ít gặp lỗi hơn so với việc tự xây dựng bộ công cụ crawler từ đầu. Bên cạnh đó, Apify cũng hỗ trợ các cơ chế quan trọng như: thiết lập thời gian chờ ngẫu nhiên, giới hạn tốc độ truy vấn, và xử lý xác thực phiên đăng nhập, giúp hạn chế nguy cơ bị chặn truy cập và đảm bảo tính liên tục của quá trình thu thập.

Quá trình thu thập dữ liệu được thực hiện trong khoảng thời gian từ tháng 10/2024 đến tháng 4/2025, bao gồm cả dữ liệu lịch sử đến từ năm 2013, đảm bảo sự đa dạng về thời gian và chủ đề. Tổng cộng, chúng em đã thu thập được hơn 12.000 bài đăng và bình luận từ các nguồn trên.

Tuy nhiên, quá trình thu thập dữ liệu không tránh khỏi những thách thức đáng kể như:

Vấn đề về quyền riêng tư và đạo đức dữ liệu: Để đảm bảo tính riêng tư, chúng em đã tiến hành ẩn danh hóa toàn bộ dữ liệu thu thập, loại bỏ các thông tin nhận dạng cá nhân như tên, hình đại diện trước khi đưa vào phân tích.

Dữ liệu không đồng nhất và nhiễu: Dữ liệu từ mạng xã hội thường chứa nhiều yếu tố không liên quan như quảng cáo, spam, hoặc các nội dung ngoài chủ đề. Chúng em đã phải phát triển các bộ lọc để loại bỏ những nội dung này.

Ngôn ngữ phi chính thống: Sinh viên thường sử dụng các từ viết tắt, biểu tượng cảm xúc, tiếng lóng và trộn lẫn nhiều ngôn ngữ (tiếng Việt, tiếng Anh, kí hiệu...), gây khó khăn cho việc xử lý tự động.

Để khắc phục những thách thức này, chúng em đã thiết kế một quy trình kiểm soát chất lượng dữ liệu sau thu thập, bao gồm việc rà soát thủ công và sử dụng các kỹ thuật lọc dữ liệu bán tự động.

3.2.2. Quy trình và tiêu chí gán nhãn cảm xúc

Sau khi thu thập dữ liệu, chúng em tiến hành gán nhãn cảm xúc cho từng đơn vị dữ liệu. Quy trình gán nhãn được thiết kế một cách có hệ thống để đảm bảo tính nhất quán và độ tin cậy của tập dữ liệu huấn luyện. Cụ thể, quá trình gán nhãn bao gồm các bước sau:

Xây dựng bộ hướng dẫn gán nhãn: Chúng em đã xây dựng một bộ hướng dẫn chi tiết để định nghĩa rõ ràng ba loại cảm xúc cần phân loại:

Tích cực (Positive): Biểu đạt sự hài lòng, khen ngợi, đánh giá cao, biết ơn hoặc các cảm xúc tích cực khác đối với nhà trường, giảng viên, cơ sở vật chất hoặc các vấn đề khác.

Tiêu cực (Negative): Biểu đạt sự không hài lòng, phàn nàn, chỉ trích, thất vọng hoặc các cảm xúc tiêu cực khác.

Trung lập (Neutral): Không thể hiện rõ ràng cảm xúc tích cực hay tiêu cực, chủ yếu là các câu hỏi, thông báo hoặc nhận xét mang tính trung tính.

Bộ hướng dẫn này không chỉ cung cấp định nghĩa chung mà còn bao gồm nhiều ví dụ cụ thể cho từng loại cảm xúc, đặc biệt là các trường hợp khó phân loại như châm biếm, mỉa mai hoặc văn bản có các cảm xúc trái chiều.

Tổ chức nhóm gán nhãn: Nhóm gán nhãn bao gồm 5 thành viên trong nhóm nghiên cứu, tất cả đều là sinh viên UTC2 nên có hiểu biết tốt về ngữ cảnh của các bài đăng và bình luận.

Quy trình gán nhãn đa cấp: Quá trình gán nhãn được thực hiện như sau:


Giai đoạn 1: Mỗi mẫu dữ liệu được gán nhãn độc lập bởi ít nhất hai thành viên.

Giai đoạn 2: Các trường hợp có sự khác biệt trong gán nhãn (khoảng 25% số mẫu) được đưa ra thảo luận chung trong nhóm để đi đến quyết định cuối cùng.

Giai đoạn 3: Một tập con ngẫu nhiên (khoảng 10%) được kiểm tra chéo bởi toàn bộ nhóm để đánh giá độ nhất quán trong gán nhãn.

Tính toán độ đồng thuận: Sử dụng chỉ số Cohen's Kappa để đánh giá mức độ đồng thuận giữa các người gán nhãn. Kết quả cho thấy độ đồng thuận đạt mức 0.84, được xem là mức độ đồng thuận "đáng kể" (substantial agreement).

Hình 3.2 minh họa quy trình gán nhãn chi tiết từ dữ liệu thô đến tập dữ liệu đã gán nhãn.



Hình 3.2 Quy trình gán nhãn dữ liệu cảm xúc

Bảng 3.1 trình bày một số ví dụ điển hình từ tập dữ liệu đã gán nhãn, minh họa cho tiêu chí phân loại của từng loại cảm xúc.

Bảng 3.1 Ví dụ về dữ liệu đã gán nhãn theo các loại cảm xúc

STT	Nội dung	Nhãn cảm xúc	Giải thích
1	“Xin chào ad. Ad cho em hỏi là bằng tốt nghiệp xếp loại khá điều kiện là tổng tích lũy phải trên 2.5 thôi hay còn điều kiện gì nữa không ạ. Cảm ơn ad.”	Trung lập	Đây là câu hỏi thông thường, không thể hiện cảm xúc rõ ràng
2	“Em rất vui khi có cơ hội được đăng ký tham gia nghiên cứu khoa học. Đây là môi trường lý tưởng để sinh viên chúng em rèn luyện tư duy, phát triển kỹ năng nghiên cứu và góp phần đóng góp cho các hoạt động học thuật của nhà trường. Em rất mong nhà trường tiếp tục tạo điều kiện để sinh viên được tham gia và phát huy tốt nhất năng lực của mình.”	Tích cực	Bài viết thể hiện sự hào hứng, biết ơn và mong muốn phát triển trong môi trường học thuật.
3	“Tính ra trường mình xét điểm rèn luyện để ấy chứ, chỉ cần không vi phạm cũng đã được loại tốt rồi”	Tích cực	Nhận xét tích cực về chính sách của nhà trường, thể hiện sự hài lòng.
4	“Ad cho em hỏi em muốn mua áo phân hiệu thì liên hệ ai ạ?”	Trung lập	Câu hỏi về thông tin, không thể hiện cảm xúc cụ thể.
5	“Em mong nhà trường giải quyết cho sinh viên thi tự do a2 đợt vừa rồi vì phần nghe thi không có mấy câu mà lỗi file nghe thi lỗi 5-6 câu	Tiêu cực	Phản ánh sự bất cập trong kỳ thi, thể hiện sự bức xúc

	như vậy thì rất ảnh hưởng đến điểm thi của sinh viên tụi em ạ. Em mong nhà trường có hướng giải quyết sớm nhất cho tụi em”		và mong muốn được giải quyết.
6	“Ad ơi cho em hỏi sao điểm tới giờ này vẫn chưa lên nữa ạ ? Cũng hơn 1 tháng rồi ạ, trong khi hạn để giáo viên chấm chỉ 10 ngày???”	Tiêu cực	Than phiền về việc công bố điểm chậm, thể hiện sự thất vọng.
7	“Cho em hỏi học kỳ vừa rồi em đã thanh toán đủ tiền học phí, bây giờ em đăng ký học kỳ hè thì lại thông báo là chưa thanh toán học phí là sao ạ.”	Tiêu cực	Thể hiện sự bối rối và bức xúc vì hệ thống báo sai thông tin học phí.

Sau quá trình gán nhãn, tập dữ liệu cuối cùng bao gồm 10.169 mẫu, với phân phối như sau: 3.282 mẫu tích cực (32,3%), 3.564 mẫu tiêu cực (35%) và 3.323 mẫu trung lập (32,7%). Tỷ lệ giữa các lớp tương đối đồng đều, tuy nhiên lớp tiêu cực có phần nhỉnh hơn. Điều này phản ánh thực tế rằng sinh viên thường có xu hướng chia sẻ trải nghiệm tiêu cực nhiều hơn so với tích cực trên các kênh mạng xã hội.

a) Thách thức và giải pháp trong thu thập và gán nhãn dữ liệu tiếng Việt

Quá trình thu thập và gán nhãn dữ liệu tiếng Việt trên mạng xã hội đặt ra nhiều thách thức đặc thù, đòi hỏi những giải pháp phù hợp. Các thách thức chính và giải pháp tương ứng bao gồm:

Ngữ nghĩa phức tạp của tiếng Việt trên mạng xã hội:

Thách thức: Tiếng Việt trên mạng xã hội thường chứa nhiều yếu tố phi chuẩn như từ viết tắt không chính thống (vd: "mik" thay vì "mình"), từ lóng mới (vd: "xiu up xiu down"), cách viết biến thể (vd: "đc", "dk" thay vì "được", "đăng ký"), và đặc biệt là hiện tượng trộn lẫn ngôn ngữ (vd: "very disappointed với dịch vụ sinh viên").

Giải pháp: Chúng em đã xây dựng một từ điển chuyển đổi để chuẩn hóa các từ viết tắt và biến thể phổ biến, đồng thời chấp nhận cả dạng gốc và dạng chuẩn hóa trong quá trình phân tích để đảm bảo không mất thông tin.

Phát hiện châm biếm và mỉa mai:

Thách thức: Một trong những thách thức lớn trong quá trình gán nhãn là việc sinh viên trên mạng xã hội thường sử dụng văn phong châm biếm, mỉa mai để thể hiện cảm xúc (ví dụ: *"Wow, tiết học thú vị quá, ngủ ngon như chưa bao giờ được ngủ"*). Điều này gây khó khăn trong việc xác định cảm xúc thực sự nếu chỉ đọc một cách bề mặt.

Giải pháp: Sửa đổi tiêu chí gán nhãn nhằm nhận diện các biểu hiện châm biếm, đồng thời chú trọng phân tích ngữ cảnh rộng hơn thay vì chỉ dựa vào câu đơn lẻ. Tuy nhiên, ở bước huấn luyện mô hình, chưa có kỹ thuật đặc thù nào được áp dụng riêng cho việc phát hiện châm biếm, do đó việc nhận diện hiện tượng này hoàn toàn dựa vào chất lượng gán nhãn ban đầu.

Cảm xúc đa chiều và mâu thuẫn:

Thách thức: Nhiều phản hồi của sinh viên chứa đựng cả yếu tố tích cực và tiêu cực (vd: *"Thầy dạy hay lắm, nhưng mà bài tập nhiều quá không làm nổi"*), gây khó khăn trong việc gán nhãn.

Giải pháp: Đối với các trường hợp phức tạp, chúng em áp dụng nguyên tắc "cảm xúc chủ đạo", trong đó xác định yếu tố nào chiếm ưu thế trong toàn bộ phát ngôn. Trong một số trường hợp, chúng em cũng xem xét tách các câu phức tạp thành các đơn vị nhỏ hơn để phân tích riêng biệt.

Sự khác biệt trong nhận thức về cảm xúc:

Thách thức: Các thành viên trong nhóm gán nhãn có thể có những diễn giải khác nhau về cùng một nội dung, dẫn đến sự không nhất quán trong tập dữ liệu.

Giải pháp: Áp dụng quy trình gán nhãn đa cấp như đã mô tả ở trên, và đặc biệt chú trọng việc thảo luận nhóm đối với các trường hợp có sự bất đồng.

Từ ngữ tục tĩu và phản cảm:

Thách thức: Một số phản hồi tiêu cực chứa ngôn từ thô tục hoặc phản cảm, cần được xử lý cẩn thận trong quá trình gán nhãn và sử dụng làm dữ liệu huấn luyện.

Giải pháp: Chúng em không loại bỏ hoàn toàn những nội dung này vì chúng vẫn chứa thông tin cảm xúc có giá trị, thay vào đó sử dụng kỹ thuật thay thế từ ngữ để giữ lại cấu trúc cảm xúc nhưng loại bỏ các yếu tố không phù hợp.

Quá trình thu thập và gán nhãn dữ liệu đã tạo ra một tập dữ liệu chất lượng cao, là nền tảng quan trọng cho các giai đoạn tiếp theo của nghiên cứu. Đặc biệt, tập dữ liệu này không chỉ có giá trị trong nghiên cứu hiện tại mà còn có thể đóng góp cho cộng

đồng nghiên cứu xử lý ngôn ngữ tiếng Việt như một nguồn tài nguyên cho các bài toán phân tích cảm xúc trên dữ liệu mạng xã hội.

3.2.3 Tiền xử lý dữ liệu

Tiền xử lý dữ liệu là bước quan trọng để chuẩn hóa văn bản tiếng Việt từ mạng xã hội, vốn chứa nhiều nhiễu như từ lóng, lỗi chính tả, emoji, và ký tự đặc biệt. Quy trình tiền xử lý bao gồm nhiều bước được triển khai cẩn thận để đảm bảo dữ liệu đầu vào phù hợp với các mô hình.

Bảng 3.2 Tóm tắt quy trình tiền xử lý dữ liệu văn bản tiếng Việt

Bước	Mô tả	Công cụ/ Thư viện	Mục tiêu
Chuẩn hoá từ viết tắt	Thay thế từ viết tắt, từ lóng bằng từ chuẩn	Từ điển tự xây dựng (520 cặp)	Chuẩn hóa ngôn ngữ phi chính thống
Xóa ký tự đặc biệt	Loại bỏ các ký tự đặc biệt, URL, khoảng trắng thừa	Biểu thức chính quy	Làm sạch dữ liệu, giảm nhiễu
Xử lý emoji	Ánh xạ emoji thành nhãn cảm xúc hoặc loại bỏ	Từ điển emoji (63 emoji)	Trích xuất thông tin cảm xúc, giảm nhiễu không cần thiết
Viết thường	Chuyển toàn bộ văn bản về chữ thường	Hàm chuẩn hóa văn bản	Đảm bảo định dạng nhất quán
Xóa số	Thay thế số bằng token "number"	Biểu thức chính quy	Loại bỏ thông tin không phục vụ phân tích cảm xúc
Loại bỏ từ dừng	Xóa từ dừng tiếng Việt không mang ý nghĩa	Danh sách từ dừng (1000 từ)	Giữ lại các từ mang ý nghĩa ngữ nghĩa hoặc cảm xúc
Tách từ	Tách câu thành chuỗi token	VnCoreNLP	Tạo dữ liệu đầu vào phù hợp với mô hình

Chuyển đổi dữ liệu	Mã hoá nhãn cảm xúc thành số và chuyển văn bản thành token ID	Công cụ mã hóa nhãn và tokenizer.	Chuẩn bị dữ liệu đầu vào số hóa cho huấn luyện mô hình.
---------------------------	---	-----------------------------------	---

Triển khai từng bước tiền xử lý

Dưới đây là mô tả chi tiết cho từng bước trong quy trình tiền xử lý:

Chuẩn hóa từ viết tắt và tiếng lóng

Một từ điển gồm 520 cặp từ viết tắt và từ chuẩn được xây dựng thủ công từ phân tích 500 bài viết và bình luận mạng xã hội. Các từ phổ biến như “mik” (mình), “ko” (không), “dc” (được), “dk” (đăng ký)... được thay thế bằng các từ tương ứng trong văn viết chuẩn. Quá trình này giúp mô hình hiểu rõ hơn về nội dung thực sự của văn bản thay vì bị nhiễu bởi từ lóng không phổ thông.

Xóa ký tự đặc biệt và chuẩn hóa định dạng

Văn bản thu thập từ mạng xã hội thường chứa nhiều ký tự không cần thiết như dấu câu lặp lại (ví dụ: “!!!”, “???”), ký tự đặc biệt (#, @, %, &...), liên kết URL, hoặc khoảng trắng dư thừa. Đặc biệt, các bài viết từ trang *Fanpage UTC2 Confession* thường có ký tự “#” kèm theo số thứ tự của bài đăng (ví dụ: “#12345”), không mang giá trị ngữ nghĩa và cần được loại bỏ. Biểu thức chính quy được sử dụng để phát hiện và xóa các thành phần này một cách tự động. Ngoài ra, toàn bộ văn bản được chuyển sang chữ thường nhằm chuẩn hóa định dạng. Các từ bị kéo dài để thể hiện cảm xúc như “đẹpppppp” cũng được xử lý rút gọn thành “đẹp”, giúp giảm phân mảnh từ vựng và tăng tính nhất quán cho mô hình xử lý sau đó.

Xử lý biểu tượng cảm xúc (emoji)

Emoji là một thành phần đặc trưng trong các văn bản mạng xã hội, mang theo nhiều sắc thái cảm xúc mà mô hình văn bản truyền thống khó nhận diện nếu không xử lý phù hợp. Để tận dụng thông tin này, chúng em đã xây dựng một từ điển gồm 63 emoji phổ biến đã được xây dựng, ánh xạ mỗi emoji sang một trong ba nhãn cảm xúc cơ bản: “Positive”, “Negative” hoặc “Neutral”. Ví dụ: 😊, 😄 sẽ được thay thế bằng “Positive”; 😞, 😭 thành “Negative”; và 😐, 😏 thành “Neutral”. Những emoji không nằm trong danh sách này sẽ bị loại bỏ bằng biểu thức chính quy nhằm tránh gây nhiễu

cho mô hình học máy. Ngoài ra, các ký tự không cần thiết như “□”, “””, hoặc dấu ngoặc kép được loại bỏ triệt để để đảm bảo văn bản đầu vào sạch và nhất quán.

Xóa số

Dữ liệu văn bản thường chứa các con số như giá tiền, ngày tháng hoặc số lượng, vốn ít khi có ý nghĩa trực tiếp trong phân tích cảm xúc. Do đó, các số sẽ được thay thế bằng token “number”, hoặc loại bỏ hoàn toàn nếu không cần thiết.

Loại bỏ từ dừng

Từ dừng là các từ không mang nhiều giá trị về mặt ngữ nghĩa hoặc cảm xúc như ‘là’, ‘và’, ‘của’, ‘ở’, v.v. Chúng em đã sử dụng danh sách khoảng 1000 từ dừng tiếng Việt từ nguồn mở trên GitHub (vietnamese-stopwords-dash.txt) để lọc bỏ các từ này, giúp mô hình tập trung vào các từ mang ý nghĩa chính trong câu.

Tách từ

Do tiếng Việt không dùng dấu cách giữa các từ ghép hoặc cụm từ, tách từ là bước cần thiết. Công cụ VnCoreNLP được lựa chọn vì hiệu quả cao trong xử lý tiếng Việt, đặc biệt là với các câu dài, nhiều từ đa nghĩa, hoặc cấu trúc phức tạp. Kết quả của bước này là một chuỗi các token phân tách rõ ràng, phù hợp với đầu vào của mô hình.

Chuyển đổi dữ liệu

Tokenization: Chuyển đổi văn bản đã tách từ thành các token theo yêu cầu của mô hình (ví dụ: WordPiece tokenizer cho BERT, SentencePiece tokenizer cho PhoBERT). Mỗi từ hoặc âm tiết trong tiếng Việt được ánh xạ thành một số nguyên tương ứng trong từ vựng của mô hình. Các câu được đệm (padding) hoặc cắt bớt để có độ dài thống nhất (tối đa 512 token), đảm bảo tương thích với kiến trúc transformer.

Padding và truncation: Chuẩn hóa độ dài các chuỗi đầu vào để phù hợp với yêu cầu của mô hình.

Mã hóa nhãn: Chuyển đổi nhãn văn bản (tích cực, tiêu cực, trung lập) thành dạng số học (Negative $\rightarrow$ 0, Neutral $\rightarrow$ 1, Positive $\rightarrow$ 2).

Kết quả tiền xử lý

Sau khi áp dụng toàn bộ các bước tiền xử lý, dữ liệu đầu vào cho mô hình đã được chuẩn hóa, loại nhiễu và tổ chức lại một cách hệ thống. Cụ thể:

Trước tiền xử lý, nhiều câu văn trong dữ liệu có dạng như sau:

“mik k thik sản phẩm này tí nào 🙄🙄 giao hàng lâu ời là lâu, nv còn ko nhiệt tình!!!”

Văn bản trên chứa nhiều yếu tố gây nhiễu như từ viết tắt/từ lóng: “mik”, “k”, “ko”, “nv”; biểu tượng cảm xúc: 🙄🙄; lặp dấu câu: “!!!”; không viết hoa, không chuẩn hóa chính tả, không tách từ.

Sau các bước xử lý như chuẩn hóa từ, xóa ký tự đặc biệt, tách từ, loại từ dừng..., câu trên trở thành:

“mình không thích sản phẩm này cảm xúc_tiêu_cực giao hàng lâu nhân_viên không nhiệt_tình”

Giải thích:

“mik” → “mình”, “k” → “không”, “nv” → “nhân_viên”

🙄🙄 → ánh xạ thành token “cảm xúc_tiêu_cực”

“lâu ời là lâu” được giữ nguyên vì mang cảm xúc, nhưng được tách từ phù hợp

Các dấu câu và ký tự đặc biệt như “!!!” được loại bỏ

Kết quả là một chuỗi token sạch, dễ hiểu, có thể đưa trực tiếp vào mô hình

Lợi ích của kết quả sau tiền xử lý

Tăng tính nhất quán: Các từ cùng nghĩa nhưng khác cách viết được chuẩn hóa về một biểu diễn duy nhất, giúp giảm phân mảnh từ vựng.

Giảm nhiễu: Ký tự lặp, emoji không rõ nghĩa, và các từ không mang giá trị cảm xúc bị loại bỏ hoặc ánh xạ hợp lý.

Tối ưu hóa cho mô hình: Văn bản đã tách từ đúng chuẩn, có thể mã hóa và đưa vào mô hình tiền huấn luyện như PhoBERT, XLM-RoBERTa một cách hiệu quả hơn.

Cải thiện hiệu suất mô hình: Dữ liệu rõ ràng, ít nhiễu giúp mô hình tập trung học các đặc trưng ngôn ngữ – cảm xúc thay vì bị phân tán bởi lỗi hình thức.

3.2.4. Các mô hình phân tích cảm xúc đề xuất

Trong nghiên cứu này, chúng em áp dụng cách tiếp cận đa mô hình, kết hợp cả phương pháp học máy truyền thống và học sâu nhằm đánh giá toàn diện hiệu quả của từng kỹ thuật trong bài toán phân tích cảm xúc tiếng Việt trên dữ liệu mạng xã hội. Sáu mô hình được triển khai bao gồm: SVM, LSTM, PhoBERT, XLM-RoBERTa, ViBERT, và ViBERT4News. Mỗi mô hình sở hữu những đặc điểm riêng biệt và phù hợp với các khía cạnh khác nhau của dữ liệu tiếng Việt.

SVM là một thuật toán học máy truyền thống nhưng vẫn thể hiện hiệu quả cao trong nhiều bài toán phân loại văn bản, đặc biệt khi số lượng dữ liệu không quá lớn. Trong triển khai cụ thể, đặc trưng văn bản được trích xuất bằng kỹ thuật Bag-of-Words kết hợp TF-IDF để biểu diễn dưới dạng vector. Thuật toán sử dụng kernel RBF để xử lý các bài toán phân loại phi tuyến, đồng thời áp dụng Grid Search để tối ưu các siêu tham số như C và γ . Chiến lược One-vs-Rest được dùng để xử lý bài toán phân loại ba lớp: tích cực, tiêu cực và trung lập.

LSTM là một kiến trúc mạng nơ-ron hồi quy (RNN) có khả năng ghi nhớ thông tin dài hạn, rất phù hợp cho dữ liệu chuỗi như văn bản. Văn bản đầu vào được biểu diễn bằng word embedding 300 chiều, huấn luyện trên dữ liệu tiếng Việt. Mô hình gồm một lớp LSTM với 128 đơn vị ẩn, sau đó là một lớp dropout (tỷ lệ 0.5) nhằm tránh overfitting, rồi đến lớp fully-connected với hàm softmax cho phân loại ba lớp. Việc huấn luyện sử dụng hàm mất mát categorical cross-entropy, thuật toán tối ưu Adam với learning rate 0.001 và batch size 64.

PhoBERT là một biến thể của BERT được tiền huấn luyện chuyên biệt cho tiếng Việt bởi VinAI Research. Trong triển khai, mô hình PhoBERT-base với 12 lớp Transformer, 768 chiều ẩn và 135 triệu tham số được sử dụng, bổ sung thêm một lớp phân loại ở đầu ra. Văn bản đầu vào được xử lý bằng tokenizer riêng, yêu cầu đã được tách từ bằng VnCoreNLP. Mô hình được huấn luyện với learning rate $2e-5$, batch size 16 trong 3 epochs và sử dụng early stopping.

XLM-RoBERTa là mô hình đa ngôn ngữ dựa trên BERT, được huấn luyện trên 100 ngôn ngữ, bao gồm tiếng Việt. Phiên bản base với 12 lớp Transformer và 270 triệu tham số được sử dụng kèm một lớp phân loại cho bài toán cảm xúc ba lớp. Tokenizer mặc định của XLM-RoBERTa được dùng với độ dài tối đa 512. Mô hình được huấn luyện với learning rate $2e-5$, weight decay 0.01, warmup 500 bước, batch size 8 trong 3 epochs và dùng early stopping sau 2 epochs không cải thiện.

ViBERT là một mô hình BERT được điều chỉnh cho tiếng Việt, phát triển bởi cộng đồng NLP Việt Nam. Mô hình sử dụng kiến trúc tương tự BERT-base với tinh chỉnh phù hợp tiếng Việt, thêm một lớp phân loại và huấn luyện toàn bộ mô hình. Tokenizer được thiết kế riêng với WordPiece dành cho tiếng Việt. Huấn luyện được thực hiện với learning rate $3e-5$, batch size 16, 4 epochs và áp dụng kỹ thuật gradient accumulation.

ViBERT4News là phiên bản ViBERT được tiền huấn luyện đặc biệt trên dữ liệu tin tức tiếng Việt, phù hợp cho phân tích cảm xúc trong các bài viết báo chí và mạng xã hội. Mô hình kế thừa kiến trúc ViBERT, thêm lớp phân loại tuyến tính và được tinh chỉnh toàn bộ mạng. Tokenizer riêng của ViBERT4News được sử dụng. Việc huấn luyện tiến hành với learning rate $2e-5$, batch size 16, trong 3 epochs có sử dụng early stopping.

3.2.5. Huấn luyện và đánh giá mô hình

Quá trình huấn luyện và đánh giá mô hình được thực hiện theo một quy trình chặt chẽ và có hệ thống nhằm đảm bảo tính khách quan và hiệu quả trong việc lựa chọn mô hình tối ưu cho bài toán phân tích cảm xúc tiếng Việt. Dữ liệu được chia thành ba tập: tập huấn luyện (train) chiếm 70%, tập xác thực (valid) chiếm 15%, và tập kiểm tra (test) chiếm 15%. Việc phân chia này được thực hiện ngẫu nhiên nhưng vẫn đảm bảo sự cân bằng nhãn giữa các tập, giúp mô hình học được đặc trưng của từng lớp một cách đầy đủ và không bị thiên lệch trong quá trình đánh giá. Trong giai đoạn huấn luyện, các siêu tham số quan trọng như learning rate, batch size và số epoch được điều chỉnh thông qua nhiều lần thử nghiệm, từ đó xác định được cấu hình tối ưu cho từng mô hình. Bên cạnh đó, để giảm thiểu hiện tượng overfitting – một vấn đề phổ biến trong huấn luyện mô hình học sâu – các kỹ thuật như dropout (ngẫu nhiên loại bỏ một số nơ-ron trong quá trình học), weight decay (phạt các trọng số lớn nhằm tránh mô hình quá phức tạp), và early stopping (dừng sớm quá trình huấn luyện khi độ chính xác trên tập xác thực không cải thiện sau một số epoch) được áp dụng đồng thời, giúp tăng cường khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng thấy.

Về mặt đánh giá, mô hình được đo lường bằng các chỉ số phổ biến như accuracy (độ chính xác), precision (độ chính xác theo lớp), recall (khả năng phát hiện đúng các mẫu thuộc một lớp nhất định) và F1-score (trung bình điều hòa giữa precision và recall), từ đó đưa ra cái nhìn toàn diện về hiệu suất phân loại. Các chỉ số này không chỉ phản ánh độ chính xác tổng thể mà còn giúp nhận biết mức độ mất cân bằng giữa các lớp nếu có. Đặc biệt, để kiểm chứng hiệu quả của mô hình PhoBERT – mô hình chính được đề xuất, các kết quả được so sánh trực tiếp với các mô hình baseline bao gồm SVM (thuật toán truyền thống), LSTM, cũng như các mô hình BERT khác đã được huấn luyện cho tiếng Việt như ViBERT, XLM-RoBERTa và ViBERT4News. Tất cả các mô hình đều được huấn luyện và đánh giá trên cùng một bộ dữ liệu và theo cùng quy trình tiền xử lý, nhằm đảm bảo sự công bằng trong việc so sánh. Kết quả thu được cho phép đánh giá


không chỉ hiệu năng tuyệt đối của từng mô hình mà còn xác định rõ ưu thế tương đối của PhoBERT trong bài toán phân tích cảm xúc ngôn ngữ tiếng Việt, từ đó đưa ra lựa chọn phù hợp nhất cho các ứng dụng thực tế.

3.2.6 Triển khai và ứng dụng

Hệ thống được triển khai dưới dạng một nền tảng web tích hợp đầy đủ các bước từ thu thập dữ liệu, xử lý và phân tích cảm xúc văn bản, theo hướng chủ động do người dùng điều khiển. Thay vì thu thập dữ liệu liên tục, hệ thống cho phép người dùng lựa chọn fanpage cụ thể của nhà trường (chẳng hạn như Diễn đàn nghe sinh viên nói, UTC2 Confession), chỉ định số lượng bài viết cần thu thập cũng như khoảng thời gian đăng bài cần phân tích. Sau khi người dùng xác nhận, hệ thống sẽ thực hiện việc thu thập bài viết theo yêu cầu, xử lý nội dung văn bản và truyền qua mô hình phân tích cảm xúc đã được huấn luyện (ví dụ PhoBERT, ViBERT4news hoặc các mô hình khác) để gán nhãn cảm xúc tích cực, tiêu cực hoặc trung lập cho từng bài viết.

Về mặt kỹ thuật, mô hình phân tích được đóng gói dưới dạng API RESTful, cho phép kết nối linh hoạt giữa phần frontend (nơi người dùng nhập yêu cầu thu thập) và backend (nơi xử lý dữ liệu và phân tích cảm xúc). Hệ thống đảm bảo thời gian xử lý nhanh, nhờ vào cơ chế xử lý lô dữ liệu hiệu quả sau mỗi lần thu thập. Toàn bộ kết quả phân tích sẽ được trình bày thông qua một dashboard tương tác, nơi người dùng có thể xem thống kê cảm xúc theo thời gian, theo từng fanpage, hoặc theo chủ đề bài viết. Ngoài ra, hệ thống còn hỗ trợ xuất báo cáo tự động dưới dạng bảng, biểu đồ hoặc tệp PDF phục vụ các mục đích trình bày, theo dõi nội bộ hoặc đánh giá định kỳ.

Về mặt ứng dụng thực tế, hệ thống mang lại nhiều lợi ích cho nhà trường trong việc theo dõi phản hồi từ cộng đồng sinh viên một cách linh hoạt, chủ động và trực quan. Người quản trị có thể nhanh chóng phát hiện các chủ đề gây quan tâm mạnh, từ đó có hành động phù hợp trước khi vấn đề lan rộng. Đồng thời, hệ thống còn hỗ trợ đánh giá hiệu quả truyền thông hoặc tác động cảm xúc của các chính sách mới thông qua phản ứng của sinh viên trên mạng xã hội. Việc không thu thập liên tục giúp tiết kiệm tài nguyên và tăng tính kiểm soát, đồng thời phù hợp với bối cảnh giáo dục nơi dữ liệu được thu thập theo từng đợt, gắn liền với các sự kiện cụ thể.



Hình 3.3 Luồng xử lý hệ thống phân tích cảm xúc từ fanpage theo yêu cầu

3.3. Ứng dụng PhoBERT vào phân chia chủ đề (Topic Modeling)

Bên cạnh việc phân tích cảm xúc, chúng em còn ứng dụng PhoBERT để tự động phát hiện và phân chia các chủ đề từ phản hồi của sinh viên. Khác với các phương pháp truyền thống như LDA (Latent Dirichlet Allocation), việc sử dụng PhoBERT mang lại khả năng hiểu ngữ cảnh sâu sắc hơn, đặc biệt phù hợp với tiếng Việt.

3.3.1. Kiến trúc mô hình

Dựa trên chính tập dữ liệu được dùng để huấn luyện mô hình phân tích cảm xúc, chúng em đã gán thêm nhãn chủ đề tương ứng cho từng câu phản hồi. Cụ thể, mỗi phản hồi được gán nhãn một trong bốn chủ đề chính: 0 - facility (cơ sở vật chất), 1 - lecturer (giảng viên), 2 - others (các chủ đề khác), và 3 - training_program (chương trình đào tạo). Sau đó, chúng em huấn luyện mô hình PhoBERT để thực hiện phân chia chủ đề dựa trên văn bản đầu vào.

3.3.2 Ưu điểm của phương pháp

So với các phương pháp phân chia chủ đề truyền thống, sử dụng PhoBERT cho phân chia chủ đề mang lại những ưu điểm sau:

Hiểu ngữ cảnh tốt hơn: PhoBERT có khả năng nắm bắt ngữ cảnh hai chiều, giúp phát hiện các chủ đề ẩn dựa trên ngữ nghĩa sâu hơn, không chỉ dựa vào sự đồng xuất hiện của từ như LDA.

Xử lý hiệu quả các văn bản ngắn: Các phản hồi của sinh viên trên mạng xã hội thường ngắn gọn, khiến các phương pháp truyền thống như LDA kém hiệu quả. PhoBERT hoạt động tốt ngay cả với các văn bản ngắn.

Phù hợp với tiếng Việt: PhoBERT được huấn luyện chuyên biệt cho tiếng Việt, hiểu rõ các đặc thù của ngôn ngữ, do đó cho kết quả phân loại chủ đề chính xác hơn so với các mô hình tổng quát.

Tự động phát hiện số lượng chủ đề: Khác với LDA đòi hỏi xác định trước số lượng chủ đề, kết hợp PhoBERT với HDBSCAN cho phép phát hiện tự động số lượng chủ đề dựa trên cấu trúc dữ liệu.

Khả năng xử lý từ đồng nghĩa và đa nghĩa: Nhờ biểu diễn từ theo ngữ cảnh, PhoBERT có thể xử lý tốt các trường hợp từ đồng nghĩa (nhiều từ cùng nghĩa) và đa nghĩa (một từ nhiều nghĩa), làm tăng chất lượng phân chia chủ đề.

3.4. Ứng dụng PhoBERT trong việc trích xuất các từ tiêu cực và tích cực

Bên cạnh đó việc phân tích cảm xúc và phân chia chủ đề, chúng em còn sử dụng PhoBERT để trích xuất các từ mang sắc thái tích cực và tiêu cực trong câu. PhoBERT là mô hình ngôn ngữ được huấn luyện chuyên biệt cho tiếng Việt, dựa trên kiến trúc BERT, giúp mô hình hiểu rõ ngữ cảnh và sắc thái của từng từ trong câu. Thay vì chỉ dừng lại ở việc phân loại cảm xúc tổng thể của văn bản, việc áp dụng PhoBERT cho phép chúng em xác định cụ thể những từ hoặc cụm từ thể hiện cảm xúc tích cực, tiêu cực hoặc trung tính một cách tự động. Điều này hỗ trợ rất nhiều trong việc phân tích sâu sắc hơn các phản hồi từ sinh viên, giúp nhận diện rõ hơn những nội dung mà người học đánh giá tốt hoặc chưa hài lòng.

Quá trình ứng dụng PhoBERT trong việc trích xuất từ tích cực và tiêu cực

Tiền xử lý văn bản: Trước khi đưa vào phân tích cảm xúc, văn bản cần trải qua một quá trình tiền xử lý. Quá trình này bao gồm việc loại bỏ các yếu tố không cần thiết như dấu câu, từ dừng (stopwords), và các biểu tượng cảm xúc (emoji). Việc này giúp mô hình làm việc với một văn bản sạch, từ đó cải thiện độ chính xác của kết quả phân tích.

Phân tích từng từ: PhoBERT không chỉ phân tích cảm xúc ở mức độ câu mà còn có thể phân tích cảm xúc của từng từ trong câu. Bằng cách sử dụng các kỹ thuật tokenization (tách từ), PhoBERT có thể tách câu thành các từ hoặc cụm từ nhỏ hơn để phân tích. Mỗi từ này sau đó sẽ được mô hình đánh giá và phân loại cảm xúc, xác định xem từ đó có mang cảm xúc tích cực, tiêu cực hay trung tính.

Phân loại cảm xúc: Mô hình PhoBERT sẽ xác định cảm xúc của từng từ trong câu thông qua ba nhãn chính: tích cực, tiêu cực và trung tính. Sau khi mô hình phân loại, các từ tích cực và tiêu cực sẽ được trích xuất để phục vụ cho các phân tích tiếp theo. Những từ này sẽ giúp chúng ta hiểu rõ hơn về cảm xúc của người nói trong câu, từ đó rút ra những đánh giá chi tiết hơn về thái độ của họ.

Lọc và kết hợp kết quả: Sau khi phân tích cảm xúc của các từ, kết quả sẽ được lọc và kết hợp để đảm bảo chỉ các từ có độ tin cậy cao được giữ lại. Việc lọc này giúp đảm bảo rằng chỉ những từ có mức độ cảm xúc rõ ràng và chắc chắn sẽ được đưa vào kết quả cuối cùng. Các từ này sẽ được phân loại theo cảm xúc tích cực, tiêu cực và trung tính.

Việc trích xuất từ cảm xúc không chỉ dừng lại ở mục đích phân tích, mà còn góp phần hỗ trợ công tác cải thiện nội dung và chất lượng hoạt động của nhà trường. Ví dụ, nếu nhiều phản hồi chứa các cụm từ tiêu cực liên quan đến “hệ thống gặp trục trặc”, “chăm điểm không rõ ràng” thì những chủ đề này sẽ được ưu tiên xem xét và cải tiến. Ngược lại, các cụm từ tích cực như “giảng viên nhiệt tình”, “môi trường học tốt” sẽ giúp xác định được những điểm mạnh cần được duy trì và phát huy. Với khả năng nắm bắt ngữ nghĩa ngữ cảnh tốt của PhoBERT, kết quả trích xuất từ cảm xúc có độ chính xác cao và phù hợp với đặc trưng ngôn ngữ tiếng Việt, đặc biệt trong môi trường học thuật và hành chính.

CHƯƠNG 4: PHÁT TRIỂN HỆ THỐNG PHÂN TÍCH THÁI ĐỘ SINH VIÊN

4.1. Cơ sở dữ liệu

4.1.1. Nguồn dữ liệu và quy trình thu thập

Dữ liệu từ mạng xã hội Facebook được thu thập từ các nguồn liên quan đến sinh viên trường Đại học Giao thông Vận tải cơ sở 2 (UTC2), bao gồm các fanpage chính thức của trường và các khoa (như *Diễn đàn nghe sinh viên nói*), các trang không chính thức như *UTC2 Confessions*, cũng như các nhóm sinh viên theo lớp, khoa hoặc sở thích chung.

Toàn bộ quá trình thu thập dữ liệu được thực hiện theo đúng quy định về đạo đức nghiên cứu và bảo mật thông tin, chỉ sử dụng các dữ liệu công khai hoặc có sự đồng ý từ người dùng, và loại bỏ toàn bộ thông tin cá nhân nhận dạng trước khi phân tích. Dữ liệu chỉ được sử dụng cho mục đích nghiên cứu khoa học.

4.1.2. Thống kê dữ liệu


Tổng số dữ liệu thu thập được là 11055 mẫu, bao gồm các bình luận và bài đăng có độ dài khác nhau. Sau khi loại bỏ các mẫu trùng lặp, không liên quan, hoặc không đủ thông tin, tập dữ liệu cuối cùng bao gồm 10169 mẫu.

Bảng 4.1 Phân bố dữ liệu của các lớp cảm xúc

Nguồn dữ liệu	Số lượng mẫu	Tỷ lệ (%)
Diễn đàn nghe sinh viên nói	4278	42,07%
UTC2 Confessions	1827	17,97%
Các nhóm sinh viên và fanpage chính thức	4064	39,96%
Tổng cộng	10169	100%

Sau khi gán nhãn thủ công, phân bố của các lớp cảm xúc trong tập dữ liệu như sau:

Từ tập dữ liệu thu thập được trên mạng xã hội liên quan đến sinh viên UTC2, kết quả phân loại cảm xúc cho thấy có 3.282 mẫu tích cực (chiếm 32,3%), 3.323 mẫu trung lập (32,7%) và 3.564 mẫu tiêu cực (35%). Về mặt độ dài, các bài đăng và bình luận có độ dài trung bình là 39 từ, trong đó ngắn nhất là 2 từ và dài nhất là 466 từ.



Hình 4.1 Phân bố dữ liệu theo các loại phản hồi

4.1.3. Tiền xử lý và phân chia dữ liệu

Sau khi thu thập, dữ liệu được tiến hành tiền xử lý theo quy trình đã mô tả ở Chương 3. Trong quá trình này, chúng em gặp một số thách thức đã nêu ở trên như sự phổ biến của các từ viết tắt trong ngôn ngữ sinh viên (ví dụ: “sv” thay cho “sinh viên”, “gv” thay cho “giảng viên”), việc sử dụng biểu tượng cảm xúc thay cho từ ngữ thông thường (ví dụ: “😊” được chuyển thành “[tích cực]”, “😞” thành “[tiêu cực]”), cũng như các vấn đề về dấu câu và khoảng trắng thừa. Những vấn đề này được xử lý thông qua việc xây dựng từ điển chuyển đổi, ánh xạ biểu tượng cảm xúc về dạng từ khóa và chuẩn hóa văn bản. Sau khi hoàn tất tiền xử lý, dữ liệu được phân chia thành ba tập: tập huấn luyện gồm 7.118 mẫu (chiếm 70%), tập xác thực gồm 1.525 mẫu (15%) và tập kiểm tra cũng gồm 1.526 mẫu (15%). Quá trình phân chia này được thực hiện theo phương pháp phân tầng (stratified sampling) để đảm bảo tỷ lệ phân bố cảm xúc được giữ nguyên ở tất cả các tập.

4.2. Độ đo đánh giá

Để đánh giá hiệu suất của các mô hình phân tích cảm xúc, chúng em sử dụng nhiều độ đo khác nhau nhằm đảm bảo phản ánh đầy đủ khả năng của mô hình trong việc phân loại. Cụ thể, các độ đo được áp dụng bao gồm:

Độ chính xác (Accuracy): Là tỷ lệ giữa số lượng mẫu được phân loại đúng và tổng số mẫu.

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)} \quad (4.1)$$

Trong đó:

TP (True Positive): Số mẫu thuộc lớp dương tính được phân loại đúng

TN (True Negative): Số mẫu thuộc lớp âm tính được phân loại đúng

FP (False Positive): Số mẫu âm tính nhưng bị phân loại nhầm thành dương tính

FN (False Negative): Số mẫu dương tính nhưng bị phân loại nhầm thành âm tính

Độ chính xác theo từng lớp (Precision): Đo lường tỷ lệ mẫu dự đoán là dương tính mà thực sự là dương tính.

$$Precision = \frac{TP}{TP + FP} \quad (4.2)$$

Độ thu hồi (Recall): Đo lường khả năng mô hình phát hiện đúng các mẫu dương tính trong toàn bộ số mẫu thực sự dương tính.

$$Recall = \frac{TP}{TP + FN} \quad (4.3)$$

F1-score (F1-macro): Là trung bình điều hòa giữa Precision và Recall, giúp cân bằng hai yếu tố này khi đánh giá. F1-macro tính trung bình theo từng lớp riêng biệt, sau đó lấy trung bình cộng kết quả của tất cả các lớp.

$$F1 - macro = \frac{2 * (Precision * Recall)}{(Precision + Recall)} \quad (4.4)$$

Hàm mất mát (Loss function): Trong quá trình huấn luyện, chúng em sử dụng Cross-Entropy Loss, là một trong những hàm mất mát phổ biến cho các bài toán phân loại đa lớp. Hàm này giúp đo lường mức độ sai lệch giữa phân phối xác suất dự đoán và phân phối nhãn thực tế, từ đó mô hình có thể điều chỉnh trọng số để cải thiện kết quả phân loại.

4.3. Kết quả thực nghiệm

4.3.1. Cấu hình huấn luyện

Các mô hình trong nghiên cứu của chúng em được huấn luyện với cấu hình phần cứng và siêu tham số như sau:

Môi trường thực nghiệm:

Các mô hình được huấn luyện và đánh giá trong hai môi trường chính là Google Colab và Kaggle Notebook, nhằm tận dụng khả năng xử lý của GPU và tài nguyên điện toán miễn phí từ nền tảng đám mây. Cụ thể:

GPU: GPU được cung cấp bởi Google Colab hoặc Kaggle (thường là NVIDIA Tesla T4 hoặc tương đương).

Hệ điều hành: Linux – hệ điều hành mặc định trên cả Google Colab và Kaggle.

Phiên bản hệ điều hành: #1 SMP PREEMPT_DYNAMIC Sun Mar 30 16:01:29 UTC 2025 (trên Google Colab).

Các thư viện chính được sử dụng: PyTorch 2.6.0, Transformers 4.49.0, VnCoreNLP 1.1.1.

Việc kết hợp hai môi trường giúp linh hoạt trong quá trình huấn luyện mô hình và so sánh hiệu suất giữa các nền tảng.

Siêu tham số huấn luyện cho mô hình PhoBERT:

- Phiên bản mô hình: PhoBERT-base-v2.
- Batch size: 8 (cho cả huấn luyện và đánh giá).
- Learning rate: $2e-5$ với lịch trình giảm dần (learning rate scheduler).
- Số epochs: 3 (với early stopping dựa trên độ chính xác trên tập validation).
- Optimizer: AdamW với weight decay 0.01.
- Max sequence length: 100 tokens.
- Dropout rate: 0.1.

Cấu hình cho các mô hình so sánh:

SVM:

- Tfidf max features: 10,000
- Tfidf n-gram range: (1, 2)
- SVM kernel: linear
- Regularization (C): 1.0
- Class weight: balanced
- Cross-validation folds: 5
- Probability estimation: enabled (True)

RNN/LSTM:

- Hidden size: 256

- Số lớp: 2
- Dropout: 0.5
- Embedding dimension: 100
- Batch size: 64

ViBERT và ViBERT4news:

Tương tự cấu hình của PhoBERT, điều chỉnh learning rate là $3e-5$

XLM-RoBERTa:

- Batch size: 16
- Learning rate: $2e-5$
- Các tham số khác tương tự PhoBERT

Để đảm bảo độ tin cậy của kết quả, chúng em chia dữ liệu thành các tập huấn luyện, validation và test theo phương pháp phân tầng, giữ nguyên tỷ lệ các lớp cảm xúc. Mô hình có hiệu suất tốt nhất trên tập validation sẽ được lưu lại và sử dụng để đánh giá trên tập test.


4.3.2. Kết quả

Dưới đây là bảng so sánh hiệu suất của các mô hình trên cùng một tập dữ liệu được đánh giá bằng độ đo accuracy, precision, recall, và f1-score (macro), bao gồm các mô hình ViBERT4News, PhoBERT, ViBERT, XLM-RoBERTa, LSTM và SVM. Các chỉ số này phản ánh độ chính xác toàn cục, khả năng nhận diện đúng nhãn theo từng lớp và độ cân bằng giữa precision và recall.

Bảng 4.2 So sánh hiệu suất của các mô hình trên tập kiểm tra

Mô hình	Accuracy	F1-score (macro)	Precision (macro)	Recall (macro)
ViBERT4News	0.9010	0.9010	0.9022	0.9015
PhoBERT	0.8912	0.8912	0.8921	0.8921
XLM-RoBERTa	0.8596	0.8596	0.8601	0.8642

Mô hình	Accuracy	F1-score (macro)	Precision (macro)	Recall (macro)
ViBERT	0.8496	0.8496	0.8521	0.8519
SVM	0.8336	0.8336	0.8402	0.8336
LSTM	0.8148	0.8148	0.8148	0.8148




Hình 4.2 Biểu đồ so sánh hiệu suất các mô hình các chỉ số


Nhìn từ bảng và biểu đồ, có thể thấy rằng ViBERT4News đạt hiệu suất cao nhất trên tất cả các chỉ số, cho thấy khả năng biểu diễn ngữ nghĩa tốt hơn so với các mô hình còn lại. PhoBERT theo sát phía sau, đặc biệt nổi bật ở độ chính xác và F1-score. ViBERT và XLM-RoBERTa đạt kết quả ổn định, phản ánh sự tổng quát tốt. Trong khi đó, các mô hình truyền thống như LSTM và SVM tuy không đạt kết quả cao nhất nhưng vẫn thể hiện hiệu quả chấp nhận được với độ phức tạp mô hình thấp hơn. Điều này cho thấy khả năng sử dụng các mô hình đơn giản trong các hệ thống yêu cầu tài nguyên thấp.

So sánh loss giữa các mô hình huấn luyện trên cùng tập dữ liệu

Biểu đồ dưới đây thể hiện so sánh training loss và validation loss giữa các mô hình. Dễ thấy rằng ViBERT4News có train loss rất thấp nhưng validation loss cao hơn so với các mô hình khác, phản ánh dấu hiệu quá khớp. Trong khi đó, các mô hình như PhoBERT và ViBERT có độ lệch giữa train/val loss nhỏ hơn, thể hiện khả năng khái quát tốt hơn.




Hình 4.3 So sánh training loss giữa các mô hình



Hình 4.4 So sánh validation loss giữa các mô hình


Diễn biến quá trình học của mô hình ViBERT4News



Hình 4.5 Diễn biến quá trình học của mô hình ViBERT4News

Mô hình đạt training loss rất thấp, cho thấy học rất tốt trên dữ liệu huấn luyện. Tuy nhiên, validation loss lại cao nhất trong các mô hình, và dao động không ổn định giữa các fold. Điều này cho thấy dấu hiệu overfitting, tức mô hình ghi nhớ dữ liệu huấn luyện thay vì học các đặc trưng tổng quát.


Diễn biến quá trình học của mô hình PhoBERT



Hình 4.6 Diễn biến quá trình học của mô hình PhoBERT

Giữ mức training loss và validation loss tương đối ổn định, với khoảng cách giữa hai đường loss không lớn. Điều này thể hiện mô hình học khá đều và có khả năng khái quát tốt. Mức validation loss gần như là thấp nhất, đi kèm hiệu suất cao trên tập test.

Diễn biến quá trình học của mô hình XLM-RoBERTa



Hình 4.7 Diễn biến quá trình học của mô hình XLM-RoBERTa

Đối với mô hình XLM-RoBERTa, mặc dù loss trên tập huấn luyện ổn định, nhưng loss trên tập validation và test lại có xu hướng tăng dần. Điều này cho thấy mô hình có thể gặp khó khăn trong việc tổng quát hoá, và tiềm ẩn nguy cơ overfitting nhẹ hoặc không ổn định giữa các fold.


Diễn biến quá trình học của mô hình ViBERT

Có training loss cao hơn ViBERT4News, nhưng lại có validation loss tương đối ổn định. Điều này cho thấy ViBERT học chậm hơn nhưng ít gặp tình trạng overfitting, có thể phù hợp với bài toán yêu cầu mô hình đơn giản, ít lệch.



Hình 4.8 Diễn biến quá trình học của mô hình ViBERT


Diễn biến quá trình học của mô hình SVM



Hình 4.9 Diễn biến quá trình học của mô hình SVM

Mặc dù không có quá trình huấn luyện theo epoch, nhưng loss qua từng fold vẫn được ghi nhận. SVM cho thấy mức train loss cao hơn, nhưng validation loss khá gần với train, thể hiện tính ổn định. Tuy nhiên, do không có quá trình fine-tune embedding như các mô hình transformer, hiệu suất bị giới hạn.

Diễn biến quá trình học của mô hình LSTM




Hình 4.10 Diễn biến quá trình học của mô hình LSTM

Đối với mô hình LSTM, đường biểu diễn validation loss cho thấy xu hướng giảm ở các bước đầu, sau đó lại tăng về sau. Điều này cho thấy mô hình ban đầu học khá tốt nhưng sau một số bước huấn luyện, đã bắt đầu overfit lên tập huấn luyện. Đây là hiện tượng phổ biến khi huấn luyện mô hình có nhiều tham số với tập dữ liệu hạn chế.


Ma trận nhầm lẫn (Confusion Matrix)

Để làm rõ khả năng phân biệt cảm xúc của các mô hình, chúng em trình bày ma trận nhầm lẫn của ba mô hình tiêu biểu: ViBERT4News – mô hình hiện đại có hiệu suất cao nhất, PhoBERT – mô hình transformer phổ biến với hiệu suất khá tốt, SVM – mô hình học máy truyền thống được dùng làm baseline.


Qua 3 ma trận nhầm lẫn dưới đây, có thể thấy rằng các mô hình dựa trên transformer (ViBERT4news, PhoBERT) có khả năng phân biệt rõ ràng giữa các cảm xúc hơn mô hình truyền thống như SVM. Điều này khẳng định lợi thế của kiến trúc deep learning trong các bài toán xử lý ngôn ngữ tự nhiên.



Hình 4.11 Ma trận nhầm lẫn của mô hình ViBERT4news



Hình 4.12 Ma trận nhầm lẫn của mô hình PhoBERT



Hình 4.13 Ma trận nhầm lẫn của mô hình SVM

Từ 3 ma trận nhầm lẫn trên, ta có bảng 4.3 trình bày tỉ lệ phân loại đúng (độ chính xác theo lớp) của các mô hình như sau:

Bảng 4.3 So sánh độ chính xác theo lớp của các mô hình

Mô hình	Tiêu cực	Trung tính	Tích cực
ViBERT4news	86.0%	89.4%	96.6%
PhoBERT	86.5%	85.8%	95.3%
SVM	80.2%	83.2%	83.7%

Dựa vào bảng trên ta có kết luận như sau:

ViBERT4news và PhoBERT (mô hình Transformer) vượt trội hơn hẳn so với SVM (mô hình truyền thống) trong nhiệm vụ phân loại cảm xúc.

Phân tích lỗi

Để hiểu rõ hơn về các trường hợp mô hình dự đoán sai, chúng em đã phân tích một số mẫu điển hình:

Bảng 4.4 Các ví dụ về dự đoán sai của mô hình PhoBERT

Văn bản	Nhãn thực	Dự đoán	Phân tích
"Cô nhiệt tình quá mức, hi vọng sẽ không gặp cô trong những môn học tới nữa"	Tiêu cực	Tích cực	Mô hình bị nhiễu bởi phần đầu tích cực
"Nhà trường tổ chức các hoạt động ngoại khóa nhưng em chưa tham gia."	Trung lập	Tiêu cực	Cụm từ "không tham gia" thường mang hàm ý tiêu cực
"Thời khóa biểu lần này sắp xếp ổn hơn rồi đấy, nhưng vẫn cần cải thiện thêm"	Tích cực	Tiêu cực	Mô hình nhạy cảm với phần nhận xét cuối

Từ các phân tích trên, chúng em nhận thấy rằng phần lớn lỗi phân loại xảy ra trong các trường hợp như: văn bản chứa đồng thời yếu tố tích cực và tiêu cực khiến mô hình khó xác định cảm xúc chính; cách diễn đạt mang tính châm biếm, mỉa mai hoặc gián tiếp gây hiểu nhầm cho mô hình; và những nhận xét trung lập nhưng sử dụng từ ngữ thường liên quan đến cảm xúc mạnh như tích cực hoặc tiêu cực cũng dễ dẫn đến dự đoán sai.

Phân tích theo chủ đề

Để cung cấp cái nhìn sâu hơn về phản hồi của sinh viên, chúng em đã phân loại các bình luận theo các chủ đề chính và đánh giá phân bố cảm xúc trong từng chủ đề. Các chủ đề được xem xét bao gồm giảng viên, chương trình học, cơ sở vật chất và các vấn đề khác. Mỗi chủ đề có sự phân bố cảm xúc khác nhau, phản ánh những cảm nhận đa dạng từ sinh viên về các yếu tố trong môi trường học tập. Tuy nhiên, khi áp dụng mô hình PhoBERT trên tập dữ liệu phân loại chủ đề, chúng em nhận được kết quả sau: Accuracy: 0.7681, F1-macro: 0.7681, Precision (macro): 0.4652, Recall (macro): 0.5421. Mặc dù độ chính xác đạt 76.81%, độ chính xác theo từng lớp (precision và recall) có sự chênh lệch rõ rệt giữa các chủ đề. Điều này có thể do dữ liệu chưa được

cân bằng trước khi đưa vào huấn luyện, dẫn đến một số chủ đề, đặc biệt là các chủ đề có ít dữ liệu hơn, không được phân loại chính xác. Những chỉ số trên cho thấy mô hình PhoBERT đã đạt được kết quả khá tốt trong việc phân loại cảm xúc theo chủ đề, nhưng vẫn có không gian cải thiện, đặc biệt trong việc cân bằng dữ liệu và tinh chỉnh các tham số mô hình.

Trích xuất các từ quan trọng

Bên cạnh việc phân chia chủ đề, chúng em còn thực hiện trích xuất các từ quan trọng từ mô hình giúp xác định các yếu tố ảnh hưởng đến cảm xúc trong văn bản. Sau đây là kết quả trích xuất từ hai mô hình có hiệu suất tốt nhất là PhoBERT và ViBERT4news cho cùng một mẫu dữ liệu.

Dữ liệu: “Trường mới sửa lại đẹp quá đi.”

Bảng 4.5 So sánh kết quả trích xuất từ và phân tích cảm xúc

Kết quả	PhoBERT	ViBERT4news
Thái độ	Positive (score: 0.94)	Neutral (score: 1.00)
Từ tích cực	mới, đẹp, lại đẹp	Không có
Từ tiêu cực	quá	Không có

Tuy nhiên, kết quả chưa thật sự hợp lý do phương pháp sử dụng còn đơn giản - chỉ tách từ và xét các trường liên quan, trong khi các mô hình BERT lại xem xét cả ngữ cảnh.

4.4. Giao diện hệ thống

Để giúp nhà trường dễ dàng tiếp cận và sử dụng kết quả phân tích cảm xúc, chúng em đã phát triển một giao diện trực quan với kiến trúc như sau:

Giao diện hệ thống được xây dựng trên kiến trúc web application, bao gồm các thành phần chính: Frontend sử dụng React.js và Tailwind CSS để tạo giao diện người dùng trực quan; Backend sử dụng FastAPI (Python) để xử lý yêu cầu và kết nối với mô hình; API sử dụng RESTful API cho phép tương tác với mô hình PhoBERT đã được huấn luyện; và dữ liệu được lưu trữ dưới dạng CSV files để lưu trữ dữ liệu phản hồi và kết quả phân tích.

NCKH Sinh Viên 2025

Phân tích cảm xúc từ sinh viên UTC2

Tình hình trường UTC2

Trường thời gian gần đây có nhiều hoạt động và vấn đề được sinh viên quan tâm, thể hiện qua các bài đăng trên Facebook. Một số sinh viên đang tìm kiếm lời khuyên về việc phúc khảo bài thi, ôn tập tiếng Anh đầu vào, và chia sẻ về trải nghiệm cá nhân. Tuy nhiên, vẫn còn một số vấn đề tồn tại như việc quản lý email sinh viên sau khi tốt nghiệp, và cách thức hoạt động của các page truyền thông của trường còn chông chéo và chưa hiệu quả. Ngoài ra, một số sinh viên cũng bày tỏ mong muốn có không gian và hoạt động xã hội tích cực hơn. Xu hướng chung cho thấy sinh viên đang tích cực tương tác và mong muốn có sự hỗ trợ và cải thiện từ trường.

🕒 Cập nhật lần cuối: 18:43:35 18/4/2025

Page	Từ ngày	Đến ngày	Hashtag	
UTC2 Confessions	mm/dd/yyyy	mm/dd/yyyy	Chọn hashtag	Tìm kiếm

Hình 4.14 Dashboard tổng quan hệ thống phân tích cảm xúc


Page	Từ ngày	Đến ngày	Hashtag	
UTC2 Confessions	04/19/2025	04/17/2025	#hocphi	Tìm kiếm

Tích cực Minh cảm ơn ❤️ Mến gửi	Tiêu cực thật sự trong lòng mình rất rất buồn Minh đã xóa tất cả phương thức liên lạc với bé đó sinh viên trường còn ngần ngại xem hướng gì nói tới mục tiêu xa vời đăng lập lại mấy page liên đăng hình thầy cô check in hay học sinh đoàn hội không ghi ai là ai như như nào đặt mỗi đúng cap cut nhún có hay không có cũng vậy	Trung lập Cho mình hỏi ở đây mn ai đã từng làm đơn phúc khảo lại bài thi kết thúc học phần chia sẻ giúp mình với ạ Minh có nên phúc khảo lại bài thi điểm thấp không và nếu mình phúc khảo lại thì có bị chấm điểm thấp hơn điểm đã nhập trên hệ thống không ạ Mong mn giải đáp giúp mình Mọi người cho e hỏi làm thế nào để
--	--	--


Hình 4.15 Giao diện phân tích theo chủ đề



Hình 4.16 Giao diện thống kê cảm xúc trên Confession



Hình 4.17 Biểu đồ xu hướng cảm xúc – 1



Hình 4.18 Biểu đồ xu hướng cảm xúc – 2



Hình 4.19 Giao diện phân tích cảm xúc của bài viết

KẾT LUẬN VÀ KIẾN NGHỊ

1. Kết luận

Nghiên cứu này của chúng em đã hoàn thành việc phát triển một hệ thống phân tích thái độ của sinh viên UTC2 trên mạng xã hội Facebook, ứng dụng các thuật toán xử lý ngôn ngữ tự nhiên (NLP) tiên tiến. Dựa trên kết quả thực nghiệm, chúng em rút ra các kết luận sau:

Mô hình ViBERT4News đạt hiệu quả cao nhất với độ chính xác 90,1%, vượt trội so với các mô hình khác như PhoBERT (89,12%), XLM-RoBERTa (85,96%), ViBERT (84,96%), SVM (83,36%) và LSTM (81,48%). Tuy nhiên, mặc dù ViBERT4News có độ chính xác cao nhất, nhưng nó cũng có sự gia tăng đáng kể về valid loss và test loss, cho thấy mô hình này có xu hướng overfitting và không ổn định khi xử lý dữ liệu kiểm tra và validation. Do đó, chúng em quyết định sử dụng PhoBERT cho các bài toán phân tích cảm xúc trong trường hợp này, vì PhoBERT có độ ổn định cao hơn với mức độ chính xác hợp lý và ít bị overfitting.

Kết quả phân tích cảm xúc theo chủ đề cho thấy sự khác biệt rõ rệt trong cảm xúc của sinh viên đối với các yếu tố khác nhau của trường như giảng viên, cơ sở vật chất, chương trình học và các vấn đề khác. Điều này cung cấp thông tin hữu ích giúp nhà trường nhận diện được các vấn đề cần cải thiện.

Việc thu thập và phân tích 10169 mẫu dữ liệu từ các nguồn mạng xã hội như UTC2 Confession đã chứng minh giá trị của dữ liệu mạng xã hội trong công tác quản lý giáo dục. Những phản hồi này thường chân thực và phản ánh chính xác cảm nhận của sinh viên, điều mà họ có thể không chia sẻ qua các khảo sát chính thức.

Kết quả nghiên cứu cũng cho thấy hệ thống phân tích cảm xúc tự động có thể trở thành công cụ hỗ trợ hiệu quả cho công tác quản lý và nâng cao chất lượng đào tạo tại UTC2, đặc biệt trong bối cảnh chuyển đổi số của ngành giáo dục.

2. Hạn chế

Mặc dù đã đạt được nhiều kết quả tích cực nhưng vẫn còn một số hạn chế cần được ghi nhận:

Thách thức với văn bản phức tạp: Mô hình vẫn gặp khó khăn trong việc phân loại chính xác các văn bản chứa cả yếu tố tích cực và tiêu cực, hoặc các biểu đạt châm biếm, mỉa mai. Đây là thách thức phổ biến trong lĩnh vực phân tích cảm xúc, đặc biệt với ngôn ngữ tiếng Việt có nhiều cách diễn đạt gián tiếp.

Giới hạn về chủ đề: Hiện tại, việc phân loại chủ đề tuy đã có mô hình phân tích những hệ thống chưa có khả năng tự động phát hiện các chủ đề mới xuất hiện trong phản hồi của sinh viên một cách hoàn toàn tự động.

Phạm vi dữ liệu: Mặc dù đã thu thập được một lượng dữ liệu đáng kể, nhưng dữ liệu vẫn chủ yếu từ Facebook và chưa bao gồm đầy đủ các nền tảng mạng xã hội khác mà sinh viên sử dụng (như Instagram, TikTok, Zalo).

Xử lý ngôn ngữ không chuẩn mực: Ngôn ngữ trên mạng xã hội thường có nhiều từ viết tắt, tiếng lóng mới, và cách viết không tuân theo quy tắc chính tả. Mặc dù đã có nỗ lực trong việc xử lý, nhưng hệ thống vẫn chưa thể bao quát hết các biến thể ngôn ngữ này.

Cân bằng giữa các lớp dữ liệu: Tập dữ liệu hiện tại có sự chênh lệch khá nhiều giữa các lớp cảm xúc (tích cực: 32.3%, trung lập: 32.7%, tiêu cực: 35%), có thể dẫn đến sự thiên lệch nhỏ trong quá trình huấn luyện mô hình.

Yêu cầu tài nguyên tính toán: Các mô hình transformer như PhoBERT đòi hỏi tài nguyên tính toán lớn, có thể gây khó khăn khi triển khai trên hệ thống có nguồn lực hạn chế.

Thiếu phân tích cấp độ khía cạnh chi tiết: Nghiên cứu hiện tại mới tập trung vào phân tích cấp độ văn bản và câu, chưa đi sâu vào phân tích cấp độ khía cạnh để hiểu rõ hơn về các yếu tố cụ thể được đề cập trong mỗi phản hồi.

3. Kiến nghị

Dựa trên kết quả nghiên cứu và các hạn chế đã xác định, chúng em đề xuất một số kiến nghị như sau:

**** Về phát triển hệ thống***

Cải thiện khả năng xử lý văn bản phức tạp: Phát triển thêm các kỹ thuật để nhận diện và xử lý tốt hơn các văn bản chứa cả yếu tố tích cực và tiêu cực, hoặc các biểu đạt châm biếm, mỉa mai. Có thể áp dụng các mô hình kết hợp để nâng cao hiệu suất.

Mở rộng nguồn dữ liệu: Thu thập thêm dữ liệu từ các nền tảng mạng xã hội khác như Instagram, TikTok, Threads, và các diễn đàn chuyên ngành để có cái nhìn toàn diện hơn về ý kiến của sinh viên.

Phát triển khả năng phân tích cấp độ khía cạnh: Nâng cấp hệ thống để có thể phân tích cảm xúc ở cấp độ khía cạnh, giúp xác định chính xác hơn các yếu tố cụ thể được đề cập trong mỗi phản hồi.

Tối ưu hóa hiệu suất: Nghiên cứu các phương pháp nén mô hình và tối ưu hóa suy luận để giảm yêu cầu tài nguyên trong khi vẫn duy trì độ chính xác cao.

Phát triển chức năng phân tích dự báo: Tích hợp các mô hình dự báo xu hướng cảm xúc dựa trên dữ liệu lịch sử để giúp nhà trường có thể chủ động trong việc đưa ra các biện pháp cải thiện.

**** Về ứng dụng thực tế tại UTC2***

Triển khai thí điểm hệ thống: Triển khai hệ thống phân tích cảm xúc theo từng giai đoạn, bắt đầu từ một số đơn vị/khoa cụ thể trước khi mở rộng toàn trường.

Phát triển hệ thống cảnh báo sớm: Xây dựng cơ chế cảnh báo tự động khi phát hiện các vấn đề tiêu cực xuất hiện với tần suất cao hoặc lan truyền nhanh chóng trên mạng xã hội.

Tích hợp với hệ thống hiện có: Kết nối hệ thống phân tích cảm xúc với các hệ thống quản lý học tập và quản lý sinh viên hiện có của trường để tạo ra một hệ sinh thái thông tin toàn diện.

Xây dựng kế hoạch cải thiện dựa trên dữ liệu: Sử dụng kết quả phân tích cảm xúc như một trong những cơ sở quan trọng để xây dựng kế hoạch cải thiện chất lượng đào tạo, dịch vụ sinh viên và cơ sở vật chất của trường.

Đánh giá tác động của các chính sách mới: Sử dụng hệ thống để theo dõi phản ứng của sinh viên trước và sau khi triển khai các chính sách hoặc thay đổi mới, giúp đánh giá tác động và hiệu quả của các quyết định.

**** Về các hướng nghiên cứu tiếp theo***

Nghiên cứu mô hình đa nhiệm vụ: Phát triển các mô hình có khả năng thực hiện đồng thời nhiều nhiệm vụ như phân loại cảm xúc, nhận dạng chủ đề, trích xuất thông tin quan trọng từ phản hồi của sinh viên.

Phân tích cảm xúc đa phương tiện: Mở rộng nghiên cứu để phân tích cảm xúc từ các dạng dữ liệu khác ngoài văn bản, như hình ảnh, video, hoặc âm thanh được sinh viên chia sẻ trên mạng xã hội.

Phân tích mạng lưới xã hội: Kết hợp phân tích cảm xúc với phân tích mạng lưới xã hội để hiểu rõ hơn về cách lan truyền của các ý kiến tích cực/tiêu cực trong cộng đồng sinh viên.

TÀI LIỆU THAM KHẢO

- [1] B. Liu, *Sentiment Analysis and Opinion Mining*. Morgan & Claypool Publishers, 2012.
- [2] L. Zhang, S. Wang, and B. Liu, “Deep learning for sentiment analysis: A survey”, *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 8, no. 4, pp. e1253, 2018.
- [3] W. Medhat, A. Hassan, and H. Korashy, “Sentiment analysis algorithms and applications: A survey”, *Ain Shams Engineering Journal*, vol. 5, no. 4, pp. 1093–1113, 2014.
- [4] B. Pang and L. Lee, “Opinion mining and sentiment analysis”, *Foundations and Trends in Information Retrieval*, vol. 2, no. 1–2, pp. 1–135, 2008.
- [5] E. Cambria, B. Schuller, Y. Xia, and C. Havasi, “New avenues in opinion mining and sentiment analysis”, *IEEE Intelligent Systems*, vol. 28, no. 2, pp. 15–21, 2013.
- [6] X. T. Vu, T. A. Nguyen, T. M. H. Nguyen, and M. D. Nguyen, “VnCoreNLP: A Vietnamese Natural Language Processing Toolkit”, In *Proceedings of NAACL-HLT 2019*, pp. 56–60, 2019.
- [7] J. Devlin, M. W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, In *Proceedings of NAACL-HLT 2019*, pp. 4171–4186, 2019.
- [8] D. Jurafsky and J. H. Martin, *Speech and Language Processing*, 3rd ed. draft, 2021.
- [9] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [10] N. L. T. Nguyen and L. Anthony, “Issues in Vietnamese word segmentation: A comparative study”, *Journal of Natural Language Engineering*, vol. 24, no. 4, pp. 567–589, 2018.
- [11] D. Q. Nguyen, T. Vu, and A. T. Nguyen, “PhoBERT: Pre trained language models for Vietnamese”, In *Findings of EMNLP 2020*, pp. 1037–1042, 2020.
- [12] T. Nguyen et al., “ViBERT: A Vietnamese BERT Model for NLP Tasks”, In *Proceedings of ACL 2020*, pp. 1-10, 2020.
- [13] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient estimation of word representations in vector space”, *arXiv preprint arXiv:1301.3781*, 2013.
- [14] J. Pennington, R. Socher, and C. D. Manning, “Glove: Global vectors for word representation”, In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pp. 1532-1543, 2014.
- [15] C. Cortes and V. Vapnik, “Support-vector networks”, *Machine learning*, vol. 20, no. 3, pp. 273-297, 1995.
- [16] A. McCallum and K. Nigam, “A comparison of event models for naive bayes text classification”, In *AAAI-98 workshop on learning for text categorization*, vol. 752, pp. 41-48, 1998.

- [17] D. R. Cox, “The regression analysis of binary sequences”, *Journal of the Royal Statistical Society. Series B (Methodological)*, vol. 20, no. 2, pp. 215-242, 1958.
- [18] J. R. Quinlan, “Induction of decision trees”, *Machine learning*, vol. 1, no. 1, pp. 81-106, 1986.
- [19] L. Breiman, “Random forests”, *Machine learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [20] T. M. Cover and P. E. Hart, “Nearest neighbor pattern classification”, *IEEE transactions on information theory*, vol. 13, no. 1, pp. 21-27, 1967.
- [21] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition”, *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278-2324, 1998.
- [22] Y. Kim, “Convolutional neural networks for sentence classification”, In *Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP)*, pp. 1746-1751, 2014.
- [23] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors”, *Nature*, vol. 323, no. 6088, pp. 533-536, 1986.
- [24] S. Hochreiter and J. Schmidhuber, “Long short-term memory”, *Neural computation*, vol. 9, no. 8, pp. 1735-1780, 1997.
- [25] D. Bahdanau, K. Cho, and Y. Bengio, “Neural machine translation by jointly learning to align and translate”, *arXiv preprint arXiv:1409.0473*, 2014.
- [26] A. Vaswani et al., “Attention is all you need”, In *Advances in neural information processing systems*, pp. 5998-6008, 2017.
- [27] K. Nguyen et al., “UIT-VSFC: Vietnamese Student Feedback Corpus for Sentiment Analysis”, In *LREC 2021*, pp. 100-110, 2021.
- [28] A. Conneau et al., “Unsupervised Cross-lingual Representation Learning at Scale”, In *ACL 2020*, pp. 7440-7451, 2020.
- [29] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [30] H. T. Vo, T. T. Nguyen, H.-A. Pham, and T. V. Le, “An Efficient Hybrid Model for Vietnamese Sentiment Analysis”, In *Proceedings of the Asian Conference on Intelligent Information and Database Systems, Lecture Notes in Computer Science*, vol. 10192, pp. 227-237, 2017.